Curs - Probabilităţi şi Statistică 2026/2027
Secţia Informatică

Facultatea de Matematică şi Informatică
Universitatea Babeş-Bolyai, Cluj-Napoca
Conf. Dr. Habil. Hannelore Lisei



Teoria Probabilităţilor

Teoria probabilităţilor este o disciplină a matematicii care se ocupă de studiul fenomenelor aleatoare.

- *aleator* = care depinde de o împrejurare viitoare şi nesigură; supus întâmplării
- provine din latină: *aleatorius*; *alea* (lat.) = zar; joc cu zaruri; joc de noroc; şansă; risc
- `Alea iacta est!` (lat.) = Zarurile au fost aruncate!

↪ se măsoară *şansele pentru succes* sau *riscul pentru insucces* al unor evenimente.

Exemple de aplicaţii în Informatică

► **Învăţare automată şi inteligenţă artificială:** Algoritmii de învăţare realizează predicţii pe baza datelor observate. Deoarece datele sunt adesea incomplete, incerte sau conţin erori (*noisy data*), se utilizează modele probabilistice pentru a cuantifica incertitudinea şi pentru a evalua predicţiile.
Exemple: filtrarea mesajelor spam, recunoaşterea imaginilor, recunoaşterea vorbirii, modelele lingvistice de mari dimensiuni (Large Language Models).

► **Algoritmi randomizaţi**[1]**:** Mulţi algoritmi eficienţi folosesc în mod intenţionat alegeri aleatoare pentru a obţine - în medie - performanţe mai bune sau pentru a simplifica modul lor de proiectare.
Exemple: `Quicksort` randomizat, funcţii de dispersie (hashing) randomizate, algoritmi de tip Monte Carlo.

► **Reţele de calculatoare:** În sistemele de comunicaţie pot apărea evenimente imprevizibile şi diverse surse de incertitudine.
Exemple: momentele de sosire ale pachetelor de date, întârzieri în reţea, erori de transmisie, întreruperi ale comunicaţiei.

► **Securitate cibernetică şi criptografie:** Sistemele criptografice moderne necesită numere aleatoare de înaltă calitate.
Exemple: generarea cheilor criptografice, vectori de iniţializare, protocoale de autentificare.

► **Jocuri pe calculator:** Introducerea unor evenimente aleatoare face jocurile mai puţin previzibile şi mai atractive.
Exemple: evenimente aleatoare în joc, recompense randomizate, comportamentul personajelor controlate de calculator.

Alte aplicaţii

→ jocuri de noroc, pariuri şi loterii;
→ prognoză meteorologică;
→ sondaje de opinie (analiza unor strategii politice), asigurări (evaluarea riscurilor / pierderilor);
→ simulări ştiinţifice şi modelare matematică (de exemplu, procese stocastice).

[1] Un algoritm pe cursul executării căruia se iau anumite decizii aleatoare este numit algoritm aleator (randomizat). Durata de execuţie, spaţiul de stocare, rezultatul obţinut sunt variabile aleatoare (chiar dacă se folosesc aceleaşi valori input). La anumite tipuri de algoritmi corectitudinea este garantată doar cu o anumită probabilitate.

Generarea numerelor aleatoare

Calculatoarele pot genera secvenţe de *numere pseudo-aleatoare* cu ajutorul unor algoritmi deterministici. Deşi aceste secvenţe par aleatoare, ele pot fi reproduse exact dacă sunt cunoscute algoritmul şi valorile iniţiale folosite.
▷ Se pot genera numere cu „adevărat aleatoare" (*true random numbers*), folosind ca surse fenomene fizice, ca de exemplu surse radioactive (momentele de timp în care particulele se dezintegrează sunt complet imprevizibile), sau variaţiile de amplitudine din perturbările atmosferice (*atmospheric noise*), sau comportamentul fotonilor (în mecanica cuantică, când un foton loveşte un separator de fascicule -*beam splitter*-, fotonul are şansa de 50% de a fi reflectat şi 50% de a trece); etc.
`https://www.random.org/randomness/`
Exemplu: Generarea de valori aleatoare (în Python)

```
import random
x = random.random()
print("Valoare aleatoare din intervalul [0,1]:",x)
N = random.randint(-1, 5)
print("numar intreg  aleator din intervalul [-1,5]:",N)
M = [random.randint(-1, 5) for _ in range(10)]
print("numere intregi aleatoare din intervalul  [-1,5]:", M)
Lista = ["AB","XY","EF","MN","FG"]
n = 5
print(n,"-extrageri aleatoare cu returnare:",random.choices(Lista, k=n))
print(n,"-extrageri aleatoare fara returnare:",random.sample(Lista, k=n))

import numpy as np
print("Numere intregi aleatoare din intervalul [-1,5):")
print(np.random.randint(-1, 5, 10))      # -1 inclus, 5 exclus
n = 5
print(n,"extrageri aleatoare cu returnare:",np.random.choice(Lista,size=n,replace=True))
print(n,"extrageri aleatoare fara returnare:",np.random.choice(Lista,size=n,replace=False)
                                                )
```

Noţiuni introductive:

• Experienţa aleatoare (experimentul aleator) este acea experienţă al cărei rezultat nu poate fi cunoscut decât după încheierea ei.
• Evenimentul este rezultatul unei experienţe aleatoare.

Exemple:

• evenimentul imposibil, notat cu $\emptyset$, este evenimentul care nu se realizează niciodată la efectuarea experienţei aleatoare
• evenimentul sigur este un eveniment care se realizează cu certitudine la fiecare efectuare a experienţei aleatoare
• spaţiul de selecţie, notat cu Ω, este mulţimea tuturor rezultatelor posibile ale experienţei considerate
  ◇ spaţiul de selecţie poate fi finit sau infinit
• dacă A este o submulţime a lui Ω atunci A se numeşte eveniment aleator, iar dacă A are un singur element atunci A este un eveniment elementar.
▷ O *analogie între evenimente şi mulţimi* permite o scriere şi o exprimare mai comode ale unor idei şi rezultate legate de conceptul de eveniment aleator.

Experiment	Eveniment
Se efectuează o extragere la loto (6 din 49).	Primul număr extras este 23.
Se transmite un pachet de date printr-o reţea de calculatoare.	Pachetul de date se pierde.
Se aplică un filtru antispam unui e-mail primit.	E-mailul este clasificat ca spam.
Se execută un algoritm de sortare randomizat.	Primul pivot ales este cel mai mic element.
Se generează un număr întreg aleator de la 1 la 100.	Numărul generat este par.
Se rulează un clasificator bazat pe învăţare automată asupra unei imagini.	Imaginea este clasificată corect.
Se transmit date printr-un canal de comunicaţie cu perturbaţii.	Cel puţin un bit este transmis corect.
Se monitorizează un server pe parcursul unei ore.	În intervalul respectiv sosesc peste 1000 de cereri.
Se simulează comportamentul unui sistem informatic.	Timpul de răspuns depăşeşte două secunde.

Exemplu 1. Experimentul: aruncarea unui zar, spaţiul de selecţie: $\Omega = \{e_1, e_2, e_3, e_4, e_5, e_6\}$,
e_i: s-a obţinut numărul i $(i = 1, \ldots, 6)$; $e_1, e_2, e_3, e_4, e_5, e_6$ sunt evenimente elementare
A: s-a obţinut un număr par $\Rightarrow A = \{e_2, e_4, e_6\}$
$\bar{A}$: s-a obţinut un număr impar $\Rightarrow \bar{A} = \{e_1, e_3, e_5\}$ ♣

Operaţii cu evenimente

• dacă $A, B \subseteq \Omega$, atunci evenimentul reuniune $A \cup B$ este un eveniment care se produce dacă cel puţin unul din evenimentele A sau B se produce

• dacă $A, B \subseteq \Omega$, atunci evenimentul intersecţie $A \cap B$ este un eveniment care se produce dacă cele două evenimente A şi B se produc în acelaşi timp

• dacă $A \subseteq \Omega$ atunci evenimentul contrar sau complemetar $\bar{A}$ este un eveniment care se realizează atunci când evenimentul A nu se realizează

• $A, B \subseteq \Omega$ sunt evenimente **disjuncte** (incompatibile), dacă $A \cap B = \emptyset$

• dacă $A, B \subseteq \Omega$, atunci evenimentul diferenţă $A \setminus B$ este un eveniment care se produce dacă A are loc şi B nu are loc, adică $A \setminus B = A \cap \bar{B}$.

• Au loc relaţiile: $A \cup \bar{A} = \Omega, \quad A \cap \bar{A} = \emptyset, \quad \bar{\bar{A}} = A.$

Relaţii între evenimente

• dacă $A, B \subseteq \Omega$, atunci A implică B, dacă producerea evenimentului A conduce la producerea evenimentului B: $A \subseteq B$

• dacă A implică B şi B implică A, atunci evenimentele A şi B sunt egale: $A = B$

Proprietăţi ale operaţiilor între evenimente $A, B, C \subseteq \Omega$
Operaţiile de reuniune şi intersecţie sunt operaţii **comutative**:

$$A \cup B = B \cup A, \quad A \cap B = B \cap A,$$

asociative

$$(A \cup B) \cup C = A \cup (B \cup C), \quad (A \cap B) \cap C = A \cap (B \cap C),$$

şi **distributive**

$$(A \cup B) \cap C = (A \cap C) \cup (B \cap C), \quad (A \cap B) \cup C = (A \cup C) \cap (B \cup C);$$

satisfac **legile lui De Morgan**

$$\overline{A \cup B} = \bar{A} \cap \bar{B}, \quad \overline{A \cap B} = \bar{A} \cup \bar{B}.$$

Frecvenţa relativă şi frecvenţa absolută

Def. 1. *Fie A un eveniment asociat unei experienţe, repetăm experienţa de n ori (în aceleaşi condiţii date) şi notăm cu $k_n(A)$ numărul de realizări ale evenimentului A; frecvenţa relativă a evenimentului A este numărul*

$$f_n(A) = \frac{k_n(A)}{n}$$

$k_n(A)$ este frecvenţa absolută a evenimentului A.

Definiţia clasică a probabilităţii

Def. 2. *Într-un experiment în care cazurile posibile sunt finite la număr şi au aceleaşi şanse de a se realiza,* ***probabilitatea*** *unui eveniment A este numărul*

$$P(A) = \frac{\textit{numărul de cazuri favorabile apariţiei lui } A}{\textit{numărul total de cazuri posibile}}.$$

► Prin repetarea de multe ori a unui experiment, în condiţii practic identice, frecvenţa relativă $f_n(A)$ de apariţie a evenimentului A este aproximativ egală cu $P(A)$: $f_n(A) \approx P(A)$ pentru valori mari ale lui n.

Exemplu 2. Un calculator generează un şir binar de lungime 4, fiecare bit fiind ales independent ca 0 sau 1, cu aceeaşi probabilitate. Considerăm spaţiul de selectie

$$\Omega = ...$$

şi evenimentul A : *şirul generat conţine exact două cifre* 1. Se calculează $P(A) = ...$

Generalizaţi rezultatul pentru cazul în care şirul binar are lungimea $n \in \mathbb{N}$, $n \geq 3$. ♣

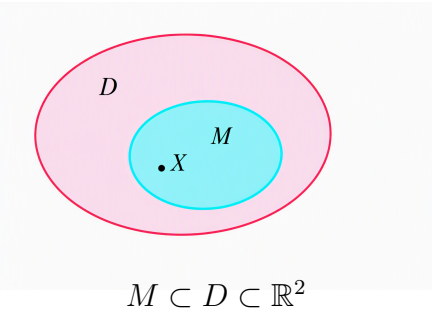
Exerciţii: (1) Se alege aleator un număr din mulţimea $\{1, 2, 3, ...99\}$.
(a) Care este probabilitatea ca acesta să fie divizibil cu 4 sau cu 6?
(b) Care este probabilitatea ca acesta să nu fie divizibil nici cu 4, nici cu 6?
(2) Un centru de calcul dispune de 24 de servere:
▷ 10 servere sunt rezervate pentru baze de date,
▷ 8 servere sunt pentru aplicaţii web,
▷ 6 servere sunt dedicate sarcinilor de învăţare automată.
Un nou proces este atribuit aleator unuia dintre servere.
▷ Care este probabilitatea ca procesul să nu ruleze pe un server de baze de date?
▷ Care este probabilitatea ca procesul să ruleze pe un server web sau de învăţare automată? ♠

Definiţia axiomatică a probabilităţii

Definiţia clasică a probabilităţii poate fi utilizată numai în cazul în care numărul cazurilor posibile este finit. Dacă numărul evenimentelor elementare este infinit, atunci există evenimente pentru care probabilitatea în sensul clasic nu are nici un înţeles.

Probabilitatea geometrică: Măsura unei mulţimi corespunde lungimii în $\mathbb{R}$, ariei în $\mathbb{R}^2$, volumului în $\mathbb{R}^3$. Fie $M \subset D \subset \mathbb{R}^n$, $n \in \{1,2,3\}$, mulţimi cu măsură finită.
Alegem aleator un punct $X \in D$ (în acest caz spaţiul de selecţie este D). Probabilitatea geometrică a evenimentului „$X \in M$" este

$$P(X \in M) := \frac{\text{măsura}(M)}{\text{măsura}(D)}.$$



$M \subset D \subset \mathbb{R}^2$

Definiţiile clasică şi geometrică ale probabilităţii sunt utile în numeroase aplicaţii, totuşi ele pot fi privite ca fiind cazuri particulare ale unui cadru mult mai general, şi anume definiţia axiomatică a probabilităţii, formulată de matematicianul A. Kolmogorov în anul 1933. Această abordare stă la baza teoriei moderne a probabilităţilor.

$\twoheadrightarrow$ $P : \mathcal{K} \to \mathbb{R}$ este o funcţie astfel încât oricărui eveniment aleator $A \in \mathcal{K}$ i se asociază valoarea $P(A)$, ***probabilitatea de apariţie a evenimentului*** A

$\hookrightarrow$ $\mathcal{K}$ este o mulţime de evenimente şi are structura unei **σ-algebre** (vezi Def. 3)
$\hookrightarrow$ P satisface anumite **axiome** (vezi Def. 4)

Def. 3. *O familie nevidă $\mathcal{K}$ de evenimente din spaţiul de selecţie Ω se numeşte **σ-algebră** dacă sunt satisfăcute condiţiile:*

(1) *dacă $A \in \mathcal{K}$, atunci $\bar{A} \in \mathcal{K}$;*

(2) *dacă $A_n \in \mathcal{K}$, $n \in \mathbb{N}^*$, atunci $\bigcup_{n=1}^{\infty} A_n \in \mathcal{K}$.*

*Perechea $(\Omega, \mathcal{K})$ se numeşte **spaţiu măsurabil**.*

Exemple: 1) Dacă $\emptyset \neq A \subset \Omega$ atunci $\mathcal{K} = \{\emptyset, A, \bar{A}, \Omega\}$ este o σ-algebră.
2) $\mathscr{P}(\Omega)$:= mulţimea tuturor submulţimilor lui Ω este o σ-algebră.
3) Dacă $\mathcal{K}$ este o σ-algebră pe Ω şi $\emptyset \neq B \subseteq \Omega$, atunci $B \cap \mathcal{K} := \{B \cap A : A \in \mathcal{K}\}$ este o σ-algebră pe mulţimea B.
4) Fie $\mathcal{A} := \big\{[\alpha, \beta] : 0 \leq \alpha \leq \beta \leq 1\big\}$ mulţimea tuturor intervalelor închise conţinute în $[0,1]$. Notăm cu $\mathcal{B}([0,1])$ familia tuturor submulţimilor lui $[0,1]$ care pot fi construite, pornind de la intervalele închise din $\mathcal{A}$ prin folosirea operaţiilor unei σ-algebre, şi anume: complementul relativ la $[0,1]$, reuniuni numărabile şi aplicarea repetată a acestor operaţii. Familia $\mathcal{B}([0,1])$ se numeşte **σ-algebra Borel pe** $[0,1]$. Ea este cea mai mică σ-algebră de submulţimi ale lui $[0,1]$ care conţine toate intervalele închise $[a,b] \subseteq [0,1]$. Perechea $\Big([0,1], \mathcal{B}([0,1])\Big)$ este un spaţiu măsurabil. Analog se defineşte spaţiul măsurabil $\Big([a,b], \mathcal{B}([a,b])\Big)$ unde $a, b \in \mathbb{R}, a < b$. ♣

P. 1. *Proprietăţi ale unei σ-algebre: Dacă $\mathcal{K}$ este o σ-algebră în Ω, atunci au loc proprietăţile:*

(1) $\emptyset, \Omega \in \mathcal{K}$;

(2) $A, B \in \mathcal{K} \Longrightarrow A \cap B,\ A \setminus B \in \mathcal{K}$;

(3) $A_n \in \mathcal{K},\ n \in \mathbb{N}^* \Longrightarrow \bigcap_{n=1}^{\infty} A_n \in \mathcal{K}$.

Def. 4. *Fie $\mathcal{K}$ o σ-algebră pe Ω. O funcţie $P : \mathcal{K} \to [0,1]$ se numeşte **probabilitate** dacă satisface axiomele:*

(1) $P(\Omega) = 1$;

(2) *pentru orice şir $(A_n)_{n\in\mathbb{N}^*}$ de evenimente două câte două disjuncte (adică $A_i \cap A_j = \emptyset$ pentru orice $i \neq j$) din $\mathcal{K}$ are loc*

$$P\Big(\bigcup_{n=1}^{\infty} A_n\Big) = \sum_{n=1}^{\infty} P(A_n)\,.$$

*Tripletul $(\Omega, \mathcal{K}, P)$ se numeşte **spaţiu de probabilitate**.*

Exemplu 3. 1) Cea mai simplă (funcţie de) probabilitate se obţine pentru cazul unui *spaţiu de selecţie finit* Ω: fie $\mathcal{K} = \mathscr{P}(\Omega)$ (mulţimea tuturor submulţimilor lui Ω) şi $P : \mathcal{K} \to [0,1]$ definită astfel

$$P(A) = \frac{\#A}{\#\Omega},\ \text{unde } \#A \text{ reprezintă numărul elementelor lui } A \in \mathscr{P}(\Omega).$$

P astfel definită verifică Def. 4 şi corespunde *definiţiei clasice a probabilităţii unui eveniment* (Def. 2).
2) Fie $\Omega = \mathbb{N} = \{0, 1, 2, \ldots\}$, $\mathcal{K} = \mathscr{P}(\mathbb{N})$ şi $P : \mathcal{K} \to [0,1]$ definită prin
$P(\{n\}) = \frac{1}{2^{n+1}}$, $n \in \mathbb{N}$
$P(\{n_1, ..., n_k, ...\}) = \frac{1}{2^{n_1+1}} + ... + \frac{1}{2^{n_k+1}} + ...$, unde $\{n_1, ..., n_k, ...\} \subseteq \mathbb{N}$.

Are loc $P(\mathbb{N}) = \sum_{n=0}^{\infty} \frac{1}{2^{n+1}} = 1$, iar axiomele din Def. 4 sunt îndeplinite.
$(\mathbb{N}, \mathscr{P}(\mathbb{N}), P)$ este un spaţiu de probabilitate.
3) Pe intervalul $[a, b]$, probabilităţile se definesc proporţional cu lungimile: Pentru orice interval $[c, d] \subseteq [a, b]$ se consideră

$$P([c, d]) = \frac{d - c}{b - a}.$$

Această definiţie determină o (funcţie de) probabilitate P pe $\mathcal{B}([a, b])$, iar $\big([a, b], \mathcal{B}([a, b]), P\big)$ este un spaţiu de probabilitate. ♣

P. 2. *Fie $(\Omega, \mathcal{K}, P)$ un spaţiu de probabilitate. Au loc proprietăţile:*

(1) $P(\bar{A}) = 1 - P(A)$*;*

(2) $P(B \setminus A) = P(B) - P(A \cap B)$*;*

(3) $A \subseteq B \Longrightarrow P(A) \leq P(B)$*, adică P este monotonă;*

(4) $P(A \cup B) = P(A) + P(B) - P(A \cap B)$.

Exerciţiu: Să se arate că pentru $\forall\ A, B, C \in \mathcal{K}$ are loc:

$$P(A \cup B \cup C) = P(A) + P(B) + P(C) - P(A \cap B) - P(A \cap C) - P(B \cap C) + P(A \cap B \cap C).$$

Exemplu: Dintr-un pachet de 52 de cărţi de joc se extrage o carte aleator. Care este probabilitatea p de a extrage a) un as sau o damă de pică? b) o carte cu inimă sau un as?
R.: a) A: s-a extras un as; D: s-a extras damă de pică; A şi D sunt două evenimente disjuncte (incompatibile)

$$p = P(A \cup D) = P(A) + P(D) = \frac{4+1}{52};$$

b) I: s-a extras o carte cu inimă; I şi A *nu* sunt evenimente incompatibile

$$p = P(I \cup A) = P(I) + P(A) - P(I \cap A) = \frac{13+4-1}{52} = \frac{4}{13}\,.$$

♡

Evenimente independente

Def. 5. *Fie $(\Omega, \mathcal{K}, P)$ un spaţiu de probabilitate. Evenimentele $A, B \in \mathcal{K}$ sunt **evenimente independente**, dacă*

$$P(A \cap B) = P(A)P(B).$$

Observaţie: Fie evenimentele $A, B \in \mathcal{K}$. Evenimentele A şi B sunt **independente**, dacă **apariţia evenimentului A, nu influenţează apariţia evenimentului B şi invers**. Două evenimente se numesc **dependente** dacă probabilitatea realizării unuia dintre ele depinde de faptul că celălalt eveniment s-a produs sau nu.
Exerciţiu: Se aruncă un zar de două ori.
A: primul număr este 6; B: al doilea număr este 5; C: primul număr este 1.
Sunt A şi B evenimente independente? Sunt A şi B evenimente disjuncte?
Sunt A şi C evenimente independente? Sunt A şi C evenimente disjuncte? ♣

P. 3. *Fie $(\Omega, \mathcal{K}, P)$ un spaţiu de probabilitate şi fie $A, B \in \mathcal{K}$. Sunt echivalente afirmaţiile:*

(1) *A şi B sunt independente.*

(2) *$\bar{A}$ şi B sunt independente.*

(3) *A şi $\bar{B}$ sunt independente.*

(4) *$\bar{A}$ şi $\bar{B}$ sunt independente.*

Def. 6. *Fie $(\Omega, \mathcal{K}, P)$ un spaţiu de probabilitate. $B_1, \ldots, B_n$ sunt **n evenimente independente (în totalitate)** din $\mathcal{K}$ dacă*

$$P(B_{i_1} \cap \cdots \cap B_{i_m}) = P(B_{i_1}) \cdot \ldots \cdot P(B_{i_m})$$

pentru orice submulţime finită $\{i_1, \ldots, i_m\} \subseteq \{1, 2, ..., n\}$, unde $m \geq 2$.

Observaţie; Din Def. 6 avem $A, B, C \in \mathcal{K}$ sunt trei evenimente independente (în totalitate), dacă

$$P(A \cap B) = P(A)P(B),\ P(A \cap C) = P(A)P(C),\ P(B \cap C) = P(B)P(C),$$

$$P(A \cap B \cap C) = P(A)P(B)P(C).$$

Exemplu: 1) Din Def. 5 şi Def. 6 deducem că, independenţa (în totalitate) implică şi independenţa a două câte două evenimente. Afirmaţia inversă, însă, nu are loc. Drept (contra)exemplu putem lua experimentul aleator ce constă în aruncarea unui tetraedru regulat, ale cărui patru feţe sunt vopsite astfel: una este roşie, una este albastră, una este verde şi una este colorată având cele trei culori. Se aruncă tetraedrul şi se consideră evenimentele:

R: tetraedrul cade pe o parte ce conţine culoarea roşie;
A: tetraedrul cade pe o parte ce conţine culoarea albastră;
V: tetraedrul cade pe o partea ce conţine culoarea verde.
Sunt cele 3 evenimente *independente în totalitate*?
2) Pentru a verifica dacă n evenimente distincte $B_1, \ldots, B_n$ sunt independente în totalitate câte relaţii trebuie verificate?
3) O firmă utilizează două sisteme de securitate independente pentru a detecta activitatea suspectă a reţelei: un firewall care detectează o astfel de activitate cu o probabilitate de 0.7 şi un antivirus care o detectează cu o probabilitate de 0.8.
Presupunând că firewall-ul i antivirusul funcţionează independent, care este probabilitatea ca:
(a) Ambele sisteme detectează activitatea suspectă?
(b) Cel puţin un sistem detectează activitatea suspectă? ♦

Exemplu istoric - Joc de zaruri (sec. XVII): Un pasionat jucător de zaruri, cavalerul de Méré, susţinea în discuţiile sale cu B. Pascal că a arunca un zar de 4 ori pentru a obţine cel puţin o dată faţa şase, este acelaşi lucru cu a arunca de 24 ori câte două zaruri pentru a obţine cel puţin o dublă de şase. Cu toate acestea, cavalerul de Méré a observat că jucând în modul al doilea (cu două zaruri aruncate de 24 ori), pierdea faţă de adversarul său, dacă acesta alegea primul mod (aruncarea unui singur zar de 4 ori). Pascal şi Fermat au arătat că probabilitatea de câştig la jocul cu un singur zar aruncat de 4 ori este $p_1 \approx 0.5177$, iar probabilitatea $p_2 \approx 0.4914$ la jocul cu două zaruri aruncate de 24 de ori. Deşi diferenţa dintre cele două probabilităţi este mică, totuşi, la un număr mare de partide, jucătorul cu probabilitatea de câştig p_1 câştigă în faţa jucătorului cu probabilitatea de câştig p_2. Practica jocului confirmă astfel justeţea raţionamentului matematic, contrar credinţei lui de Méré.
Estimăm prin simulări Python probabilităţile următoarelor evenimente:
A: se obţine cel puţin un 6 în 4 aruncări ale unui zar;
B: se obţine cel puţin o pereche (6,6) în 24 de aruncări a două zaruri;
C: se obţine cel puţin o pereche (6,6) în 25 de aruncări a două zaruri.

Calculăm probabilităţile teoretice pentru evenimentele A, B, C: $\bar{A}$ este evenimentul că niciun 6 nu apare în 4 aruncări ale unui zar

$$\Longrightarrow P(\bar{A}) = \left(\frac{5}{6}\right)^4 \Longrightarrow P(A) = 1 - \left(\frac{5}{6}\right)^4 \approx 0.5177.$$

$\bar{B}$ este evenimentul că nicio pereche $(6,6)$ nu apare în 24 de aruncări a două zaruri

$$\Longrightarrow P(\bar{B}) = \left(\frac{35}{36}\right)^{24} \Longrightarrow P(B) = 1 - \left(\frac{35}{36}\right)^{24} \approx 0.4914\,.$$

Analog $P(C) = 1 - \left(\frac{35}{36}\right)^{25} \approx 0.5055$. Comparăm probabilităţile teoretice ale celor trei evenimente

$$P(B) < \frac{1}{2} < P(C) < P(A).$$

Concluzie: Evenimentul A are şansele cele mai mari de câştig. ♢

```
import random
import numpy
a=0
N=10000
for _ in range(N):
    x=random.choices([1,2,3,4,5,6],k=4) # alegere aleatoare cu returnare
```

```
    a=a+(x.count(6)>0)
print("din simulari P(A) este:",a/N)
b=0
for _ in range(N):
    x1=random.choices([1,2,3,4,5,6],k=24)
    x2=random.choices([1,2,3,4,5,6],k=24)
    s=numpy.add(x1,x2)
    b=b+(sum(s==12)>0)
print("din simulari P(B) este:",b/N)
c=0
for _ in range(N):
    y1=random.choices([1,2,3,4,5,6],k=25)
    y2=random.choices([1,2,3,4,5,6],k=25)
    s=numpy.add(y1,y2)
    c=c+(sum(s==12)>0)
print("din simulari P(C) este:",c/N)
X=[a,b,c]
str="ABC"
z=sorted([a,b,c])
i0= X.index(z[0]) # index din X pt care este probabilitatea cea mai mica
i1= X.index(z[1])
i2= X.index(z[2]) # index din X pt care este probabilitatea cea mai mare
print("P(",str[i0],")< P(",str[i1],")< P(",str[i2],")")
# probabilitatile evenimentelor afisate in ordine crescatoare
```

Probabilitate condiţionată

În anumite situaţii este necesar să cunoaştem probabilitatea unui eveniment particular, care urmează să aibă loc, ştiind deja că alt eveniment a avut loc.

► Experiment: Se aruncă simultan două zaruri. Notăm cu S suma numerelor rezultate din aruncarea celor două zaruri.

a) $P(S = 11) =?$

b) Dacă se ştie că S este un număr prim, care este probabilitatea ca $S = 11$?

Adică $P(S = 11|S$ este un număr prim$) =?$

► Pentru a calcula o probabilitate condiţionată, luăm în considerare numai rezultatele pentru care condiţia dată este adevărată.

Def. 7. *Fie $(\Omega, \mathcal{K}, P)$ un spaţiu de probabilitate şi fie $A, B \in \mathcal{K}$.* ***Probabilitatea condiţionată a evenimentului A de către evenimentul B*** *este $P(\cdot|B) : \mathcal{K} \to [0, 1]$ definită prin*

$$P(A|B) = \frac{P(A \cap B)}{P(B)},$$

dacă $P(B) > 0$. $P(A|B)$ este ***probabilitatea apariţiei evenimentului A, ştiind că evenimentul B s-a produs****.*

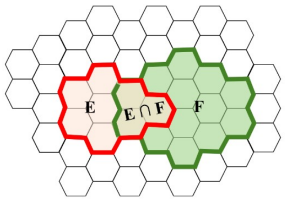
➤ $P(A|B)$: probabilitatea condiţionată a lui A de către B, este **probabilitatea de a se realiza evenimentul *A* dacă în prealabil s-a realizat evenimentul *B***.

➤ Fie evenimentele $A, B \in \mathcal{K}$ astfel încât $P(A) > 0$ şi $P(B) > 0$. Evenimentele A şi B sunt **independente** (a se vedea Def. 5), dacă apariţia evenimentului A, nu influenţează apariţia evenimentului B şi invers, adică

$$P(A|B) = P(A) \text{ şi } P(B|A) = P(B)\,.$$

➤ Într-un experiment în care cazurile posibile sunt finite la număr şi au aceleaşi şanse de a se realiza, atunci
se poate folosi

$$P(E|F) = \frac{\text{numărul de cazuri favorabile apariţiei lui } E \cap F}{\text{numărul de cazuri favorabile pentru apariţia lui } F}.$$

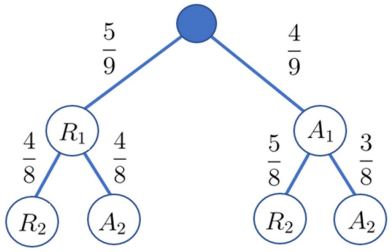


$P(E) = \frac{8}{50} \approx 0.16$

$P(E|F) = \frac{3}{14} \approx 0.21$

Exemplu 4. Se extrag succesiv fără returnare două bile dintr-o urnă cu 4 bile albe şi 5 bile roşii.

a) Ştiind că prima bilă este roşie, care este probabilitatea (condiţionată) ca a doua bilă să fie albă?
b) Care este probabilitatea ca ambele bile să fie roşii?
R.: pentru $i \in \{1, 2\}$ fie evenimentele
R_i: la a i-a extragere s-a obţinut o bilă roşie;
$A_i = \bar{R}_i$: la a i-a extragere s-a obţinut o bilă albă;
a) $P(A_2|R_1) = \frac{4}{8}$.
b) $P(R_1 \cap R_2) = P(R_2|R_1)P(R_1) = \frac{4}{8} \cdot \frac{5}{9}$. ♣

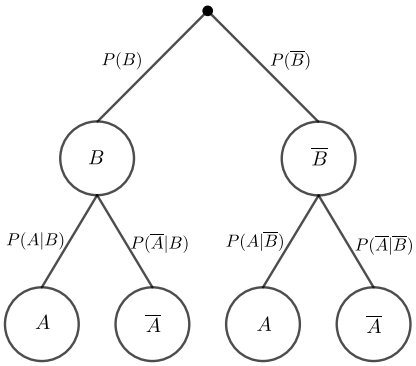


Extragere fără retrunare

P. 4. *Pentru* $A, B \in \mathcal{K}, P(A) > 0, P(B) > 0$ *au loc:*

$$P(A \cap B) = P(B)P(A|B) = P(A)P(B|A)\,,$$

$$P(\bar{A}|B) = 1 - P(A|B).$$



Probabilităţi condiţionate

Def. 8. *O familie* $\{H_1, \ldots H_n\} \subset \mathcal{K}$ *de evenimente din* Ω *se numeşte* ***partiţie*** *sau* ***sistem complet de evenimente*** *a lui* Ω, *dacă* $\bigcup_{i=1}^{n} H_i = \Omega$ *şi pentru fiecare* $i, j \in \{1, \ldots, n\}$, $i \neq j$, *evenimentele* H_i *şi* H_j *sunt disjuncte, adică* $H_i \cap H_j = \emptyset$.

Exemplu 5. Dacă $B \subset \Omega$ atunci $\{B, \bar{B}\}$ formează o partiţie a lui Ω. ♠

P. 5. ***(Formula probabilităţii totale)*** *Într-un spaţiu de probabilitate* $(\Omega, \mathcal{K}, P)$ *considerăm partiţia* $\{H_1, ..., H_n\}$ *a lui* Ω *cu* $H_i \in \mathcal{K}$ *şi* $P(H_i) > 0 \; \forall \, i \in \{1, \ldots, n\}$, *şi fie* $A \in \mathcal{K}$. *Atunci are loc*

$$P(A) = P(A|H_1)P(H_1) + ... + P(A|H_n)P(H_n).$$

Exemplu 6. Într-o urnă sunt 7 bile albe, notate cu 1, 2, 3, 4, 5, 6, 7, şi 6 bile roşii notate cu 8, 9, 10, 11, 12, 13. Se extrag succesiv fără returnare două bile. **a)** Ştiind că prima bilă extrasă este roşie, care este probabilitatea, ca numărul de pe bilă să fie divizibil cu 4? **b)** Care este probabilitatea ca a doua bilă extrasă să fie roşie? **c)** Ştiind că

prima bilă este roşie, care este probabilitatea, ca o a doua bilă extrasă să indice un număr impar?
R.: 7 bile albe: 1, 2, 3, 4, 5, 6, 7; 6 bile roşii: 8, 9, 10, 11, 12, 13.
Se consideră evenimentele:
D_1: prima bilă extrasă are înscris un număr divizibil cu 4;
R_1: prima bilă extrasă este roşie;
R_2: a doua bilă extrasă este roşie;
I_1: prima bilă extrasă are înscris un număr impar;
I_2: a doua bilă extrasă are înscris un număr impar.
a) $P(D_1|R_1) = \frac{2}{6} = \frac{1}{3}$.
b) $P(R_2) = ?$

$$\text{P.5} \Longrightarrow P(R_2) = P(R_2|R_1)P(R_1) + P(R_2|\bar{R}_1)P(\bar{R}_1) = \frac{5}{12}\cdot\frac{6}{13} + \frac{6}{12}\cdot\frac{7}{13} = \frac{72}{156} = \frac{6}{13}.$$

c) $P(I_2|R_1) = ?$ Folosim Def.7 şi P.4, scriem succesiv

$$P(I_2|R_1) = \frac{P(I_2 \cap R_1)}{P(R_1)} = \frac{P(I_2 \cap R_1 \cap I_1) + P(I_2 \cap R_1 \cap \bar{I}_1)}{P(R_1)}$$
$$= \frac{P(I_2|R_1 \cap I_1)P(R_1 \cap I_1) + P(I_2|R_1 \cap \bar{I}_1)P(R_1 \cap \bar{I}_1)}{P(R_1)} = \frac{\frac{6}{12}\cdot\frac{3}{13} + \frac{7}{12}\cdot\frac{3}{13}}{\frac{6}{13}} = \frac{13}{24}.$$

♣

Exemplu: Ce probabilităţi calculează programul de mai jos?
⑦ Care sunt valorile teoretice pentru `p1`, `p2`, `p3`, din acest exemplu?

```
import random; import numpy
c1,c2,a1,a2=0,0,0,0
N=10000
A= list(range(1,21))
for _ in range(N):
 i=numpy.random.randint(len(A))
 v=A[i]
 c1=c1+(v%2)
 c2=c2+((v%2)==0)
 a1=a1+(v%2)*((v%3)==0);
 a2=a2+ ((v%2)==0)*(6<=v and v<=10)
p1=a1/c1
p2=a2/c2
p3=c1/N
print(f"p1={p1:.6f}")
print(f"p2={p2:.6f}")
print(f"p3={p3:.6f}")
```

♣

P. 6. ***(Formula înmulţirii probabilităţilor)***
Fie $(\Omega, \mathcal{K}, P)$ *un spaţiu de probabilitate şi fie* $A_1, \ldots, A_n \in \mathcal{K}$ *astfel încât* $P(A_1 \cap \cdots \cap A_{n-1}) > 0$. *Atunci,*

$$P(A_1 \cap \cdots \cap A_n) = P(A_1)P(A_2|A_1)\ldots P(A_n|A_1 \cap \cdots \cap A_{n-1}).$$

Observaţie: 1) Formula înmulţirii probabilităţilor a două evenimente ($n = 2$) este

$$P(A_1 \cap A_2) = P(A_1)P(A_2|A_1).$$

2) În cazul, în care evenimentele aleatoare $A_1, \ldots, A_n$ sunt *independente în totalitate*, atunci formula înmulţirii probabilităţilor are forma

$$P(A_1 \cap \cdots \cap A_n) = P(A_1)P(A_2)\ldots P(A_n).$$

Exemplu 7. Într-o urnă sunt 2 bile verzi şi 3 bile albastre. Se extrag 2 bile succesiv, fără returnare. Care este probabilitatea ca
a) prima bilă să fie verde, iar cea de-a doua albastră?
b) cele 2 bile să aibă aceeaşi culoare?
c) a doua bilă să fie albastră?
d) prima bilă să fie verde, *ştiind* că a doua este albastră?
e) se mai extrage o a treia bilă; se cere probabilitatea ca prima bilă să fie verde, cea de-a doua albastră şi a treia tot albastră.

R.: Notăm pentru $i \in \{1, 2, 3\}$ evenimentele:
A_i: la a i-a extragere s-a obţinut bilă albastră; V_i: la a i-a extragere s-a obţinut bilă verde;
a) folosim P.4: $P(V_1 \cap A_2) = P(A_2|V_1)P(V_1) = \frac{3}{4} \cdot \frac{2}{5}$

b) $P((V_1 \cap V_2) \cup (A_1 \cap A_2)) = P(V_1 \cap V_2) + P(A_1 \cap A_2) = P(V_2|V_1)P(V_1) + P(A_2|A_1)P(A_1) = \frac{1}{4} \cdot \frac{2}{5} + \frac{2}{4} \cdot \frac{3}{5}$

c) folosim formula probabilităţii totale P.5:
$P(A_2) = P(A_2|V_1)P(V_1) + P(A_2|A_1)P(A_1) = \frac{3}{4} \cdot \frac{2}{5} + \frac{2}{4} \cdot \frac{3}{5}$

d) folosim P.4: $P(V_1|A_2) = \frac{P(V_1 \cap A_2)}{P(A_2)} = \frac{P(A_2|V_1)P(V_1)}{P(A_2)} = \frac{\frac{3}{4} \cdot \frac{2}{5}}{\frac{3}{4} \cdot \frac{2}{5} + \frac{2}{4} \cdot \frac{3}{5}}$

e) formula de înmulţire a probabilităţilor P.6:
$P(V_1 \cap A_2 \cap A_3) = P(V_1) \cdot P(A_2|V_1) \cdot P(A_3|V_1 \cap A_2) = \frac{2}{5} \cdot \frac{3}{4} \cdot \frac{2}{3}$.

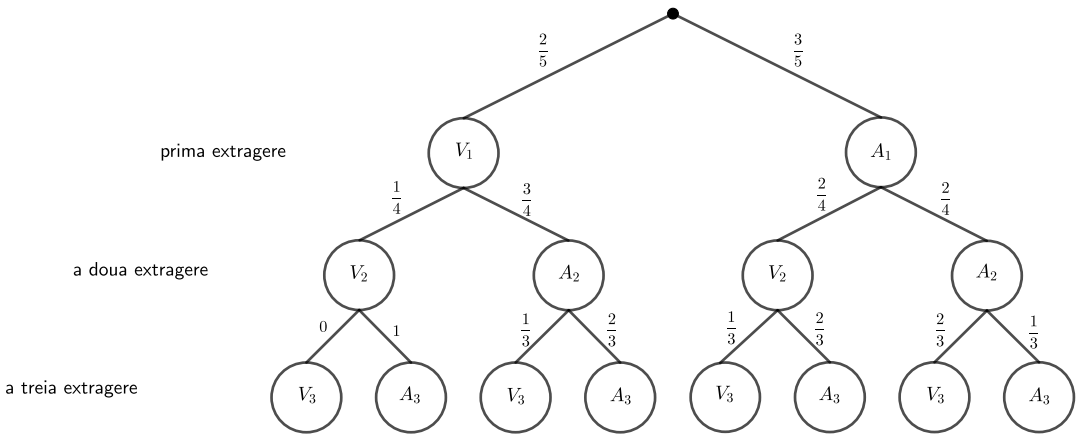


Fig. 3. Extragere fără returnare

♣

Formula lui Bayes

Formula lui Bayes este o metodă de a „corecta" (a revizui, a îmbunătăţi) pe baza unor noi date (informaţii) disponibile o probabilitate determinată apriori.
► Se porneşte cu o estimare pentru probabilitatea unei anumite ipoteze H (engl. *hypothesis*).
$\hookrightarrow P(H)$ probabilitatea ca ipoteza H să fie adevărată, numită şi ***probabilitatea apriori***
► Dacă avem noi date (date de antrenare, dovezi, informaţii, evidenţe - engl. *evidence*) E, ce privesc ipoteza H, se poate calcula o probabilitate „corectată" pentru ipoteza H, numită probabilitate posterioară (a-posteriori)

$\hookrightarrow$ probabilitatea condiţionată $P(H|E)$ este ***probabilitatea posterioară*** (corectată de cunoaşterea noilor date / informaţii / evidenţe);
▶ Se cunosc:
$\hookrightarrow$ $P(E|H)$ probabilitatea ca să apară datele, ştiind că ipoteza H este adevarată;
$\hookrightarrow$ $P(E|\bar{H})$ probabilitatea ca să apară datele, ştiind că ipoteza H este falsă
acestea reprezintă verosimilitatea (engl. *likelihood*) datelor observate (a informaţiilor / evidenţelor).

Exemplu 8. Un clasificator de emailuri este conceput pentru a detecta mesajele `spam`. Fiecare email este clasificat într-una dintre cele două categorii:
• S: un email este `spam`
• $\bar{S}$: un email nu este `spam`
C: un email conţine cuvântul *succes*.
Se cunosc probabilităţile

$$P(S) = 0.2, \text{ deci } P(\bar{S}) = 0.8 \text{ (probabilităţile apriori)},$$

$$P(C|S) = 0.7,\ P(C|\bar{S}) = 0.1.$$

Care este probabilitatea ca un email să fie `spam`, ştiind că emailul conţine cuvântul *succes*?
R: Scriem succesiv

$$P(S|C) = \frac{P(S \cap C)}{P(C)} = \frac{P(C|S) \cdot P(S)}{P(C)} = \frac{P(C|S) \cdot P(S)}{P(C|S) \cdot P(S) + P(C|\bar{S}) \cdot P(\bar{S})}.$$

Calculăm (folosim P.5 cu partiţia $\{S, \bar{S}\}$)

$$P(C) = P(C|S) \cdot P(S) + P(C|\bar{S}) \cdot P(\bar{S}) = 0.7 \cdot 0.2 + 0.1 \cdot 0.8) = 0.22$$

$$\Longrightarrow P(S|C) = \frac{0.7 \cdot 0.2}{0.22} = \frac{0.14}{0.22} \approx 0.636 \text{ (probabilitatea posterioară)}.$$

▷ Probabilitatea ca un email să fie clasificat `spam`, ştiind că emailul conţine cuvântul *succes* este 0.636.

♣

P. 7. (Formula lui Bayes)
Într-un spaţiu de probabilitate $(\Omega, \mathcal{K}, P)$ *consideră partiţia* $\{H_1, \ldots, H_n\}$ *a lui* Ω *cu* $H_i \in \mathcal{K}$ *şi* $P(H_i) > 0$ $\forall\, i \in \{1, \ldots n\}$*, şi fie* $E \in \mathcal{K}$ *astfel încât* $P(E) > 0$*. Atunci,*

$$P(H_j|E) = \frac{P(E|H_j)P(H_j)}{P(E)} = \frac{P(E|H_j)P(H_j)}{P(E|H_1)P(H_1) + \ldots + P(E|H_n)P(H_n)} \quad \forall\, j \in \{1, 2, \ldots, n\}.$$

▷ pentru $i \in \{1, 2, \ldots, n\}$ $P(H_i)$ sunt **probabilităţi apriori** pentru H_i, numite şi ipoteze (aserţiuni; engl. *hypothesis*)
▷ E se numeşte **evidenţă** (dovadă, premisă, informaţie; engl. *evidence*);
▷ cu formula lui Bayes se calculează probabilităţile pentru ipoteze, cunoscând evidenţa: $P(H_j|E)$, $j \in \{1, 2, \ldots, n\}$, care se numesc **probabilităţi posterioare** (ulterioare);
▷ $P(E|H_i)$, $i \in \{1, 2, \ldots, n\}$, reprezintă verosimilitatea (engl. *likelihood*) datelor observate.
▷ Se pot calcula probabilităţile *cauzelor*, date fiind (cunoscând / ştiind) *efectele*; formula lui Bayes ne ajută să diagnosticăm o anumită situaţie sau să testăm o ipoteză.

Exemplu (problemă de clasificare): **Cât de bun este filtrul de spam?**

• H: un email este `spam` (în realitate)

• $\bar{H}$: un email este `non-spam` (în realitate)

Un filtru de spam trebuie să clasifice emailurile în `spam` (evenimentul E) sau `non-spam` (evenimentul $\bar{E}$).

Se pune problema de a face o predicţie / prognoză asupra unui email ales aleator, dacă acesta este `spam` sau `non-spam` cu ajutorul filtrului de spam.

Au fost colectate următoarele date statistice:

▷ $AP = 400$ (adevărat pozitiv) Numărul de emailuri care sunt de fapt `spam` şi care au fost clasificate ca `spam` de către filtrul de spam ; $\#(H \cap E)$[2]

▷ $FP = 210$ (fals pozitiv) Numărul de emailuri care sunt de fapt `non-spam` şi care au fost clasificate ca fiind `spam` de filtrul de spam ; $\#(\bar{H} \cap E)$

▷ $FN = 310$ (fals negativ) Numărul de emailuri care sunt de fapt `spam` şi care au fost clasificate ca `non-spam` de filtrul de spam ; $\#(H \cap \bar{E})$

▷ $AN = 1200$ (adevărat negativ) Numărul de emailuri care sunt de fapt `non-spam` şi care au fost clasificate ca `non-spam` de filtrul de spam; $\#(\bar{H} \cap \bar{E})$.

Matricea de confuzie este utilizată pentru a vizualiza performanţa unui clasificator (de exemplu, a filtrului de spam).

		starea actuală (realitatea)		
		H (email este `spam`)	$\bar{H}$ (email este `non-spam`)	total
predicţia	E (email este clasificat `spam`)	AP	FP	AP+FP
	$\bar{E}$ (email este clasificat `non-spam`)	FN	AN	FN+AN
	total	AP+FN	FP+AN	AP+FP+FN+AN

Matricea de confuzie (engl. *confusion matrix*)

		starea actuală (realitatea)		
		H: email este `spam`	$\bar{H}$: email este `non-spam`	total
predicţia	E: email este clasificat `spam`	400 (adevărat pozitiv AP)	210 (fals pozitiv FP)	610
	$\bar{E}$: email este clasificat `non-spam`	310 (fals negativ FN)	1200 (adevărat negativ AN)	1510
	total	710	1410	2120

Matricea de confuzie construită cu datele statistice din acest exemplu

Pe baza datelor statistice: a) probabilitatea ca un email, despre care se ştie că fost clasificat `spam`, să fie în realitate `spam`, este

$$P(H|E) = \frac{400}{610} \approx 0.65 \text{ (valoarea predictivă pozitivă);}$$

[2] $\#(H \cap E)$ = numărul de alemente din $H \cap E$.

b) probabilitatea ca un email, despre care se ştie că fost clasificat `non-spam`, să fie în realitate `non-spam` este

$$P(\bar{H}|\bar{E}) = \frac{1200}{1510} \approx 0.79 \text{ (valoarea predictivă negativă).}$$

♣

diagnosticare	*machine learning (ML)*
măsuri de performanţă	*measuring the performance of a binary classification model*
valoarea predictivă pozitivă=$\frac{AP}{AP+FP}$	*positive predictive value; precision*
valoarea predictivă negativă=$\frac{AN}{AN+FN}$	*negative predictive value*
sensibilitatea=$\frac{AP}{AP+FN}$	*recall; probability of detection; true positive rate*
specificitatea=$\frac{AN}{AN+FP}$	*true negative rate*
acurateţea=$\frac{AP+AN}{AP+FP+AN+FN}$	*accuracy*

★ Probabilităţile condiţionate sunt folosite în probleme de clasificare, în teoria deciziilor, în predicţie, în diagnosticare, etc.

Variable aleatoare

→ Variabilele aleatoare apar ca funcţii, ce depind de rezultatul (aleator) al efectuării unui anumit experiment.
Exemplu: 1) La aruncarea a două zaruri, suma numerelor obţinute este o variabilă aleatoare
$S : \Omega \to \{2, 3, ..., 12\}$, unde Ω conţine toate evenimentele elementare ce se pot obţine la aruncarea a două zaruri, adică $\Omega = \{(\omega_i^1, \omega_j^2) : i, j = \overline{1,6}\}$, unde
(ω_i^1, ω_j^2) este evenimentul elementar: la primul zar s-a obţinut numărul i şi la al doilea zar s-a obţinut numărul j, unde $i, j = \overline{1,6}$.
Astfel, $P(S = 5) = \frac{4}{36}, P(S = 6) = \frac{5}{36}$, etc.
2) Un jucător aruncă două monede $\Rightarrow \Omega = \{(c, p), (c, c), (p, c), (p, p)\}$ (c=cap; p=pajură)

X indică de câte ori a apărut pajură: $\Rightarrow X : \Omega \to \{0, 1, 2\}$

$\Rightarrow P(X = 0) = P(X = 2) = \frac{1}{4}, P(X = 1) = \frac{1}{2}$ ■

Notaţie 1. *variabilă / variabile aleatoare → v.a.*

O variabilă aleatoare este:
► **discretă**, dacă ia un număr finit de valori $(x_1, \ldots, x_n)$ sau un număr infinit numărabil de valori $(x_1, \ldots, x_n, \ldots)$

► **continuă**, dacă valorile sale posibile sunt nenumărabile şi sunt într-un interval (sau reunine de intervale) sau în $\mathbb{R}$

V.a. discrete: exemple de v.a. numerice discrete: numărul produselor defecte produse de o anumită linie de producţie într-o săptămână; numărul apelurilor telefonice într-un call center în decursul unei ore; numărul de accesări ale unei anumite pagini web în decursul unei anumite zile (de ex. duminica); numărul de caractere transmise eronat într-un mesaj de o anumită lungime; exemple de v.a. categoriale (→ se clasifică în categorii): prognoza meteo: *ploios, senin, înnorat, ceţos*; calitatea unor servicii: *nesatisfăcătoare, satisfăcătoare, bune, foarte bune, excepţionale*, etc.

V.a. continue sunt v.a. numerice continue: timpul de funcţionare până la defectare a unei piese electronice,

temperatura într-un oraş, viteza înregistrată de radar pentru maşini care parcurg o anumită zonă, cantitatea de apă de ploaie (într-o anumită perioadă), duritatea unui anumit material, etc.

Variabile aleatoare numerice - definiţie formală

Def. 9. *Fie* $(\Omega, \mathcal{K}, P)$ *spaţiu de probabilitate.* $X : \Omega \to \mathbb{R}$ *este o variabilă aleatoare, dacă*

$$\{\omega \in \Omega \, : \, X(\omega) \leq x\} \in \mathcal{K} \ \textit{pentru fiecare} \ x \in \mathbb{R}.$$

Variabile aleatoare discrete $X : \Omega \to \{x_1, x_2, \ldots, x_i, \ldots\}$

Def. 10. ***Distribuţia de probabilitate*** *a v.a. discrete* X

$$X \sim \begin{pmatrix} x_1 & x_2 & \ldots & x_i & \ldots \\ p_1 & p_2 & \ldots & p_i & \ldots \end{pmatrix} = \begin{pmatrix} x_i \\ p_i \end{pmatrix}_{i \in I}$$

$I \subseteq \mathbb{N}$ *(mulţime de indici nevidă);* $p_i = P(X = x_i) > 0$*,* $i \in I$*, cu* $\sum_{i \in I} p_i = 1$.

▷ O variabilă aleatoare discretă X este caracterizată de distribuţia de probabilitate!
▷ Notăm $\{X = x_i\} = \{\omega \in \Omega : X(\omega) = x_i\}, i \in I$; acesta este un eveniment din $\mathcal{K}$ pentru fiecare $i \in I$.
$\mathbb{X} = (X_1, \ldots, X_m)$ este un **vector aleator discret** dacă fiecare componentă a sa este o variabiă aleatoare discretă.

Distribuţii discrete clasice

Distribuţia discretă uniformă: $X \sim Unid(n), \ n \in \mathbb{N}^*$

$$X \sim \begin{pmatrix} 1 & 2 & \ldots & n \\ \frac{1}{n} & \frac{1}{n} & \ldots & \frac{1}{n} \end{pmatrix}$$

Exemplu: Se aruncă un zar, fie X v.a. care indică numărul apărut

$$\Rightarrow X \sim \begin{pmatrix} 1 & 2 & \ldots & 6 \\ \frac{1}{6} & \frac{1}{6} & \ldots & \frac{1}{6} \end{pmatrix}$$

➤ Python: `scipy.stats.randint`

```
# Examplu Unid(6)  - Histograma
from scipy.stats import randint
import numpy as np
import matplotlib.pyplot as plt
N = 4000
a = 1
b = 7
R = randint.rvs(a, b, size=N)
x, count = np.unique(R, return_counts=True)
print("Valorile:", x, "au frecventele absolute:", count)
print("Valorile:", x, "au frecventele relative:", count/N)
plt.hist(R,bins=np.arange(a-0.5,b+0.5,1),density=True,color="cyan",edgecolor="black")
plt.grid()
plt.xlabel("valorile")
plt.ylabel("frecvente relative")
plt.title("Unid(6)")
plt.xticks(range(a, b))
plt.show()
```

Distribuţia Bernoulli: $X \sim Bernoulli(p), p \in (0,1)$

$$X \sim \begin{pmatrix} 0 & 1 \\ 1-p & p \end{pmatrix}$$

Exemplu: în cadrul unui experiment poate să apară evenimentul A (*succes*) sau $\bar{A}$ (*insucces*)
$X = 0 \Leftrightarrow$ dacă $\bar{A}$ apare; $X = 1 \Leftrightarrow$ dacă A apare
$\Rightarrow X \sim Bernoulli(p)$ cu $p := P(A)$

$$X \sim \begin{pmatrix} 0 & 1 \\ 1-P(A) & P(A) \end{pmatrix}$$

♣

➤ Python: `scipy.stats.bernoulli`

Distribuţia binomială: $X \sim Bino(n,p), n \in \mathbb{N}^*, p \in (0,1)$
în cadrul unui experiment poate să apară evenimentul A (*succes*) sau $\bar{A}$ (*insucces*)
• $A =$ succes cu $P(A) = p$, $\bar{A} =$ insucces $P(\bar{A}) = 1-p$
• se repetă experimentul de n ori
• v.a. X= numărul de succese în n repetări independente ale experimentului $\Rightarrow$ valori posibile: $X \in \{0,1,\dots,n\}$

$$P(X=k) = C_n^k p^k (1-p)^{n-k}, \quad k \in \{0,\dots,n\}.$$

$$X \sim Bino(n,p) \iff X \sim \begin{pmatrix} k \\ C_n^k p^k (1-p)^{n-k} \end{pmatrix}_{k \in \{0,\dots,n\}}$$

Exemple: 1) Un zar se aruncă de 10 ori, fie X v.a. care indică de câte ori a apărut numărul 6 $\Rightarrow X \sim Bino(10, \frac{1}{6})$.
2) O echipă de marketing trimite un email promoţional către 100 de abonaţi. Pe baza unor date statistice, se ştie că fiecare abonat citeaşte emailul cu probabilitatea 0.25 (independent de ceilalţi abonaţi). Definim:
▷ n numărul de încercări; $n = 100$ de emailuri trimise
▷ p probabilitatea de succes; $p = 0.25$ (probabilitatea ca un email să fie citit)
▷ X variabila aleatoare; X = numărul de emailuri deschise (din cele n trimise)
⑦ Care este probabilitatea ca exact 30 de persoane să citească emailul promoţional?
⑦ Care este probabilitatea ca mai puţin de 20 de persoane să îl citească? ♣

→ formula binomială $(a+b)^n = \sum_{k=0}^{n} C_n^k a^k b^{n-k}$ pentru $a = p$ şi $b = 1-p$ se obţine

$$1 = \sum_{k=0}^{n} C_n^k p^k (1-p)^{n-k}.$$

Exemplu: Un client accesează o dată pe zi o anumită pagină web cu probabilitatea 0.6. Cu ce probabilitate clientul accesează această pagină în total de 3 ori în următoarele 10 zile? R.: $C_{10}^3 0.6^3 0.4^7$
➤ Python: `scipy.stats.binom`

```
# Exemplu distributia binomiala Bino(n,p)
import numpy as np
import matplotlib.pyplot as plt
from scipy.stats import binom
N = 5000
n = 10
p = 0.6
```

```
date = binom.rvs(n, p, size=N)
z, count = np.unique(date, return_counts=True)
print("Valorile", z, "\n au frecventele relative:", count/N)
# histograma frecventelor relative
plt.hist(date,bins=np.arange(-0.5,n+1.5,1),density=True,color="yellow",edgecolor="black")
s = np.sum(date == 3)
print("Clientul acceseaza pag. de 3 ori in urmatoarele 10 zile cu prob.", s/N)
plt.grid()
plt.xlabel("valorile distributiei")
plt.ylabel("frecvente relative")
plt.title(f"Bino({n},{p})")
plt.xticks(range(0, n + 1))
plt.show()
```

▷ Distribuţia binomială corespunde **modelului cu extragerea bilelor dintr-o urnă cu bile de două culori şi cu returnarea bilei după fiecare extragere**:
Într-o urnă sunt n_1 bile albe şi n_2 bile negre. Se extrag cu returnare n bile; fie v.a. X_1 = numărul de bile albe extrase; X_2 = numărul de bile negre extrase
$\Rightarrow X_1 \sim Bino(n, p_1)$ cu $p_1 = \frac{n_1}{n_1+n_2}$, $X_2 \sim Bino(n, p_2)$ cu $p_2 = \frac{n_2}{n_1+n_2}$.

▷ **Modelul urnei cu r culori cu returnarea bilei după fiecare extragere:** fie p_i probabilitatea de a extrage o bilă având culoarea c_i, $i = \overline{1,r}$ dintr-o urnă; fie X_i v.a. ce indică numărul de bile de culoarea c_i, $i = \overline{1,r}$, după n extrageri *cu returnarea bilei extrase*, iar ordinea de extragere a bilelor de diverse culori nu contează

$$P(X_1 = k_1, \ldots, X_r = k_r) = \text{ probabilitatea de a obţine } k_i \text{ bile având culoarea } c_i,\ i = \overline{1,r},$$
$$\text{din } n = k_1 + \ldots + k_r \text{ extrageri } \textit{cu returnarea} \text{ bilei extrase}$$
$$= \frac{n!}{k_1! \ldots k_r!} \cdot p_1^{k_1} \cdot \ldots \cdot p_r^{k_r}$$

▷ $(X_1, ..., X_r)$ este un vector aleator discret şi urmează distribuţia multinomială
▷ distribuţia multinomială modelează experimentele în care se extrag cu returnare un număr specific $n = k_1 + \ldots + k_r$ de obiecte (elemente) din r categorii, dintr-o mulţime dată de obiecte, care au probabilităţile $p_1 = \frac{n_1}{n_1+\ldots+n_r}, ..., p_r = \frac{n_r}{n_1+\ldots+n_r}$, unde n_i este numărul de obiecte din categoria a i-a ($i = \overline{1,r}$).
▷ cazul $r = 2$ corespunde distribuţiei binomiale (modelul binomial cu bile de două culori într-o urnă)
➤ Python: `scipy.stats.multinomial`

Exerciţii: 1) O reţea de laborator este compusă din 15 calculatoare. Reţeaua a fost atacată de un virus nou, care atacă un calculator cu o probabilitatea 0.4, independent de alte calculatoare. Care este probabilitatea ca virusul a atacat
a) cel mult 10; b) cel puţin 10; c) exact 10
calculatoare?
2) Sondaj de opinie: O companie PR studiază modul în care oamenii interacţionează cu mass-media în prezent. Pentru a înţelege comportamentul publicului, se realizează un sondaj. Fiecare participant la sondaj este întrebat: *Pentru a vă informa, ce tip de mass-media utilizaţi cel mai frecvent?*
Participanţii trebuie să aleagă una dintre următoarele opţiuni:
`Televiziune/Reţele sociale/Ziare tipărite/Ştiri online/Radio`.
Pe baza cercetărilor anterioare şi a tendinţelor de interacţiune cu mass-media, următoarele date statistice sunt disponibile:
`Televiziune`: 30%
`Reţele sociale`: 35%
`Ziare tipărite`: 5%

`Ştiri online`: 20%
`Radio`: 15%
Compania doreşte să calculeze probabilitatea de a observa următoarea distribuţie într-un eşantion de 100 de persoane:
30 persoane aleg `Televiziunea`
40 aleg `Reţelele sociale`
0 aleg `Ziarele tipărite`
30 aleg `Ştirile online`
0 aleg `Radio`.
Cu ce formulă se calculează această probabilitate?

♣

Distribuţia hipergeometrică: $X \sim Hyge(n, n_1, n_2),\ n, n_1, n_2 \in \mathbb{N}^*$
Într-o urnă sunt n_1 bile albe şi n_2 bile negre. Se extrag **fără returnare** n bile.
Fie v.a. X = numărul de bile albe extrase $\Rightarrow$ valori posibile pentru X sunt $\{0, 1, \ldots, n^*\}$ cu

$$n^* = \min(n_1, n) = \begin{cases} n_1 & \text{dacă } n_1 < n \text{ (mai puţine bile albe decât numărul de extrageri)} \\ n & \text{dacă } n_1 \geq n \text{ (mai multe bile albe decât numărul de extrageri)} \end{cases}$$

Fie $n_1, n_2, n \in \mathbb{N}$ cu $n \leq n_1 + n_2$ şi notăm $n^* = \min(n_1, n)$.

$$\Rightarrow\ P(X = k) = \frac{C_{n_1}^k C_{n_2}^{n-k}}{C_{n_1+n_2}^n}, \quad k \in \{0, \ldots, n^*\}.$$

➤ Python: `scipy.stats.hypergeom`

▷ **Modelul urnei cu r culori şi bilă nereturnată:** fie n_i =numărul iniţial de bile având culoarea c_i din urnă, $i = \overline{1, r}$; fie X_i v.a. ce indică numărul de bile de culoarea c_i, $i = \overline{1, r}$, după n extrageri *fără returnarea bilei extrase*, iar ordinea de extragere a bilelor de diverse culori nu contează

$$\begin{aligned} P(X_1 = k_1, \ldots, X_r = k_r) = &\text{ probabilitatea de a obţine } k_i \text{ bile având culoarea } c_i,\ i = \overline{1, r}, \\ &\text{din } n = k_1 + \ldots + k_r \text{ extrageri } \textit{fără returnarea} \text{ bilei extrase,} \\ &= \frac{C_{n_1}^{k_1} \cdot \ldots \cdot C_{n_r}^{k_r}}{C_{n_1+\ldots+n_r}^n}. \end{aligned}$$

▷ $(X_1, \ldots, X_r)$ este un vector aleator discret şi urmează distribuţia hipergeometrică multidimensională
▷ distribuţia hipergeometrică multidimensională modelează experimentele în care se extrag fără returnare un număr specific $n = k_1 + \ldots + k_r$ de obiecte (elemente) din r categorii, dintr-o mulţime finită de obiecte $n_1 + \ldots + n_r$, unde n_i este numărul iniţial de obiecte din categoria a i-a ($i = \overline{1, r}$).
▷ Cazul $r = 2$ corespunde distribuţiei hipergeometrice.
➤ Python: `scipy.stats.multivariate_hypergeom`

Exemple: 1) Într-o urnă sunt $n_1 = 2$ bile albe şi $n_2 = 3$ bile negre. Se extrag fără returnare $n = 3$ bile. Fie v.a. X = numărul de bile albe extrase. Vom calcula $P(X = 1)$:
Prima metodă: Pentru $i \in \{1, 2, 3\}$ fie evenimentele
A_i: la a i-a extragere s-a obţinut bilă albă
$N_i = \bar{A}_i$: la a i-a extragere s-a obţinut bilă neagră.

Scriem

$$P(X=1) = P(A_1 \cap N_2 \cap N_3) + P(N_1 \cap A_2 \cap N_3) + P(N_1 \cap N_2 \cap A_3),$$
$$P(A_1 \cap N_2 \cap N_3) = P(A_1)P(N_2|A_1)P(N_3|A_1 \cap N_2) = \frac{2}{5} \cdot \frac{3}{4} \cdot \frac{2}{3} = \frac{1}{5}$$
$$P(N_1 \cap A_2 \cap N_3) = P(N_1)P(A_2|N_1)P(N_3|N_1 \cap A_2) = \frac{3}{5} \cdot \frac{2}{4} \cdot \frac{2}{3} = \frac{1}{5}$$
$$P(N_1 \cap N_2 \cap A_3) = P(N_1)P(N_2|N_1)P(A_3|N_1 \cap N_2) = \frac{3}{5} \cdot \frac{2}{4} \cdot \frac{2}{3} = \frac{1}{5}$$
$$\Rightarrow P(X=1) = \frac{3}{5}.$$

A doua metodă: O bilă albă din două se poate alege în $C_2^1 = 2$ moduri, două bile neagre din trei se pot alege în $C_3^2 = 3$ moduri, trei bile din cinci se pot alege în $C_5^3 = 10$ moduri

$$\Rightarrow P(X=1) = \frac{C_2^1 \cdot C_3^2}{C_5^3} = \frac{2 \cdot 3}{10} = \frac{3}{5}.$$

2) Loto 6 din 49: Care este probabilitatea de a nimeri exact 4 numere câştigătoare?
R.: Între cele 49 de bile exact $n_1 = 6$ sunt câştigătoare ("bilele albe") şi $n_2 = 43$ necâştigătoare ("bilele negre"). Probabilitatea ca din $n = 6$ extrageri fără returnare, exact $k = 4$ numere să fie câştigătoare (ordinea nu contează) este $p = \frac{C_6^4 C_{43}^2}{C_{49}^6}$.
▷ Fie v.a. X numărul de numere ghicite, jucând cu o singură variantă la "Loto 6 din 49". Scrieţi distribuţia de probabilitate a v.a. X.
3) O echipă de marketing se pregăteşte să testeze o nouă campanie promoţională. Baza lor de date cu clienţi conţine:

390 de clienţi atenţi la buget
310 de clienţi fideli mărcii
250 de cumpărători impulsivi
50 de clienţi VIP.

Din cauza unor constrângeri bugetare, se selectează aleator (şi fără returnare) 40 de clienţi pentru campania de testare. Care este probabilitatea ca eşantionul selectat să includă:

15 de clienţi atenţi la buget
10 clienţi fideli mărcii
10 cumpărători impulsivi
5 clienţi VIP? ♢

Distribuţia geometrică $X \sim Geo(p), p \in (0,1)$
În cadrul unui experiment poate să apară evenimentul A (*succes*) sau $\bar{A}$ (*insucces*)
• A = succes cu $P(A) = p$, $\bar{A}$ = insucces $P(\bar{A}) = 1 - p$
• se repetă (independent) experimentul până apare prima dată A ("succes")
• v.a. X arată de câte ori apare $\bar{A}$ (numărul de "insuccese") *până la* apariţia primului A ("succes") $\Rightarrow$ valori posibile: $X \in \{0, 1, \dots\}$

$$P(X=k) = p(1-p)^k \quad \text{pentru } k \in \{0, 1, 2, \dots\}.$$

➤ Python: `scipy.stats.geom`; atenţie valorile generate sunt de la 1; adică $P(Y=k) = p(1-p)^{k-1}$ pentru $k \in \{1, 2, \dots\}$, iar $X = Y - 1$ cu $X \sim Geo(p)$.
Exemplu: X v.a. ce indică numărul de retransmisii printr-un canal cu perturbări (aleatoare) până la (înainte de) prima recepţie corectă a mesajului $\Rightarrow$ X are distribuţie geometrică. ♠

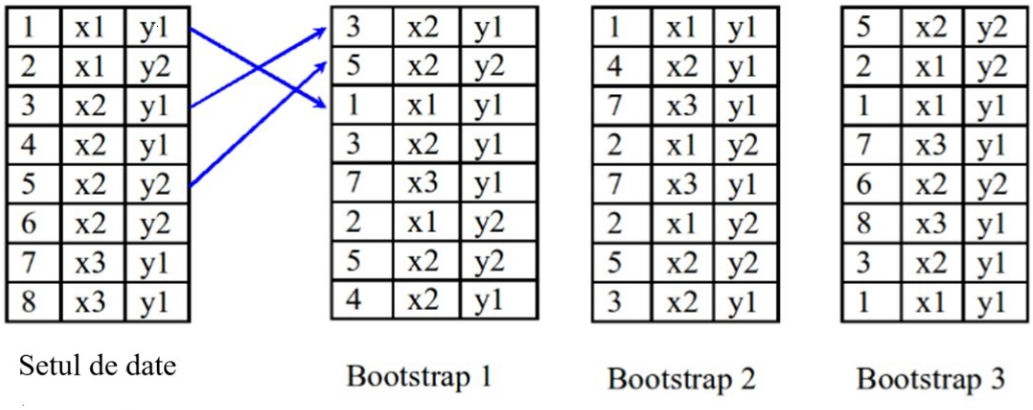
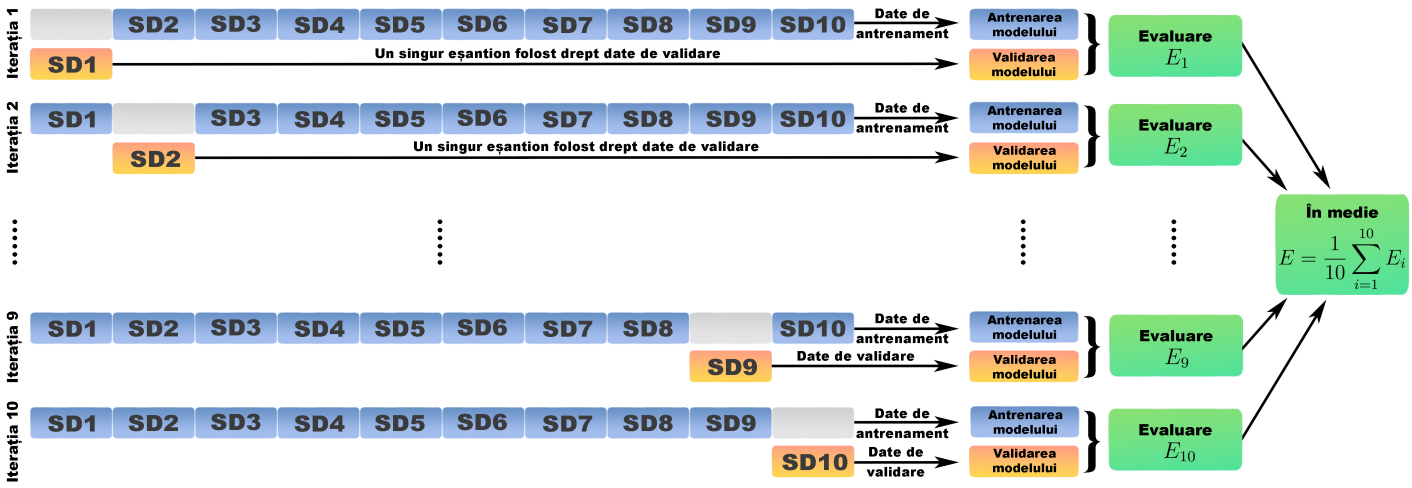


Fig.: **Exemplu - Metoda bootstrap**

Exerciţiu: Considerăm v.a. X ca fiind numărul format astfel: dintr-o cutie cu 9 bile numerotate de la 1 la 9 sunt extrase aleator, succesiv, fără returnare, 2 bile, formând astfel un număr din două cifre, prima cifră fiind numărul primei bile, iar cea de-a doua cifră, fiind numărul celei de-a doua bile extrase.
a) Determinaţii distribuţia de probabilitate a v.a. X.
b) Calculaţi probabilitatea $P(X < 90)$.

➪ Extragerea cu returnare este folosită în **metoda bootstrap** (engl. *bootstrapping*), care, în statistică, este o metodă utilizată pentru estimarea proprietăţilor unui set de date. Tehnica implică re-eşantionarea (engl. *resampling*) datelor dintr-un eşantion cu n observaţii. Un eşantion *bootstrap* este format din n observaţii alese aleator, independent şi cu returnare, din eşantionul iniţial.
➡ Denumirea *bootstrap* provine din expresia engleză *to pull oneself up by one's bootstraps*, care, în sens figurat, înseamnă „a reuşi prin propriile forţe". Prin analogie, metoda bootstrap utilizează datele disponibile pentru a estima proprietăţi statistice (de exemplu, estimarea preciziei unei medii, a unor proporţii, a unui coeficient de regresie, a unor erori, etc.) fără a apela la informaţii suplimentare despre populaţia din care provin datele.



Validarea încrucişată, $k = 10$ **(SD=set de date)**

➪ **Partiţionarea aleatoare a datelor** $\mapsto$ **metoda validării încrucişate (engl.** ***cross validation*****):**
Validarea încrucişată oferă un exemplu practic de *eşantionare fără returnare*. În cazul validării încrucişate (k-*fold cross validation*), eşantionul original de date este împărţit *aleatoriu* în k sub-eşantioane de dimensiuni egale. Din cele k sub-eşantioane (engl. *folds*), un singur sub-eşantion este folosit ca *date de validare* pentru testarea modelului considerat, iar celelalte $k-1$ sub-eşantioane sunt utilizate ca *date de antrenament*. Procesul de validare încrucişată se repetă apoi de k ori, fiecare dintre cele k sub-eşantioane fiind utilizat exact o dată ca date de validare. Avantajul acestei metode constă în faptul că toate observaţiile sunt utilizate atât pentru antrenare, cât şi pentru validare, iar fiecare observaţie este utilizată pentru validare exact o dată. Validarea încrucişată este o tehnică de evaluare a unui model de învăţare automată şi de testare a performanţei acestuia. Metoda este folosită pentru compararea şi selectarea unui model adecvat în cazul unei probleme specifice de modelare predictivă.

Exemplu 9. Un set de date conţine 1000 de mesaje e-mail etichetate drept `spam` sau `non-spam`. Pentru evaluarea unui clasificator, se utilizează validarea încrucişată ($k = 10$). Setul de date este împărţit în 10 sub-eşantioane, fiecare conţinând câte 100 de observaţii. În prima iteraţie, 900 de observaţii sunt folosite pentru antrenare, iar celelalte 100 pentru validare. Presupunem că clasificatorul clasifică corect 92 dintre cele 100 de mesaje e-mail din setul de validare. Atunci acurateţea este

$$E_1 = \frac{\text{numărul de clasificări corecte}}{\text{numărul total de clasificări}} = \frac{92}{100} = 0.92.$$

Repetând evaluarea pentru toate cele 10 sub-eşantioane, se obţin

$$E_1 = E_6 = 0.92, \quad E_2 = E_9 = 0.90, \quad E_3 = 0.94, \quad E_4 = E_8 = 0.91, \quad E_5 = E_{10} = 0.93, \quad E_7 = 0.95.$$

Estimarea globală pentru acurateţea metodei de clasificare este

$$E = \frac{1}{10}\sum_{i=1}^{10} E_i = 0.921.$$

Prin urmare, ne aşteptăm ca metoda de clasificare folosită să clasifice corect aproximativ 92.1% dintre noile mesaje e-mail. ♣

Variabile aleatoare independente

Def. 11. *Fie $X_1, \ldots, X_n$ cu $n \in \mathbb{N}$, $n \geq 2$, variabile aleatoare discrete, care iau valori în mulţimile $\mathcal{X}_1, \ldots, \mathcal{X}_n$. $X_1, \ldots, X_n$ sunt **variabile aleatoare independente**, dacă şi numai dacă*

$$P(X_1 = x_1, \ldots, X_n = x_n) = P(X_1 = x_1) \cdot \ldots \cdot P(X_n = x_n)$$

pentru fiecare $x_1 \in \mathcal{X}_1, \ldots, x_n \in \mathcal{X}_n$.

Observaţie: Fie evenimentele $A = \{X_1 = x_1\},\ x_1 \in \mathcal{X}_1$ şi $B = \{X_2 = x_2\},\ x_2 \in \mathcal{X}_2$.
V.a. X_1 şi X_2 sunt independente $\Longleftrightarrow \forall\ (x_1, x_2) \in \mathcal{X}_1 \times \mathcal{X}_2$ evenimentele A şi B sunt evenimente independente (a se vedea Def. 5).

Exemplu 10. 1) Se aruncă o monedă de 10 ori. Fie X v.a. care indică de câte ori a apărut pajură în primele cinci aruncări ale monedei; fie Y v.a. care indică de câte ori a apărut pajură în ultimele cinci aruncări ale monedei. Sunt X şi Y v.a. independente? Care este distribuţia de probabilitate a lui X, respectiv Y?
2) Se aruncă patru zaruri. Fie X_i v.a. care indică numărul apărut la al i-lea zar.
a) X_1, X_2, X_3, X_4 sunt v.a. independente;
b) $X_1 + X_2$ şi $X_3 \cdot X_4$ sunt v.a. independente;
c) $X_1 \cdot X_2 + X_3$ şi X_4 sunt v.a. independente.

Def. 12. *$\mathbb{X} = (X_1, \ldots, X_m)$ este un **vector aleator discret** dacă fiecare componentă a sa este o variabiă aleatoare discretă.*

▷ Vectorii aleatori sunt caracterizaţi de distribuţiile lor de probabilitate! De exemplu, un vector aleator discret cu două componente:

$$\mathbb{X} = (X, Y) \sim \begin{pmatrix} (x_i, y_j) \\ p_{ij} \end{pmatrix}_{(i,j) \in I \times J} \text{ unde } I, J \subseteq \mathbb{N} \text{ sunt mulţimi de indici,}$$

$p_{ij} := P\big((X, Y) = (x_i, y_j)\big) = P(\{X = x_i\} \cap \{Y = y_j\}), p_{ij} > 0\ \forall\ i \in I, j \in J, \sum\limits_{(i,j) \in I \times J} p_{ij} = 1.$

▷ Distribuţia vectorului aleator discret (X, Y) se poate da sub formă tabelară:

X \ Y	...	y_j	...
⋮	⋮	⋮	⋮
x_i	...	p_{ij}	...
⋮	⋮	⋮	⋮

Exemplu: Fie vectorul aleator discret (X, Y) cu distribuţia dată de următorul tabel:

X \ Y	0	1
-1	$\frac{1}{4}$	$\frac{1}{2}$
2	$\frac{1}{8}$	$\frac{1}{8}$

$\Longrightarrow P(X = -1, Y = 0) = \frac{1}{4}, P(X = -1, Y = 1) = \frac{1}{2}$, etc.

a) Să se determine $P(X = -1)$, $P(X \leq 3)$, respectiv $P(Y = 1)$, $P(Y \leq -1)$.
b) Sunt X şi Y v.a. independente?

Observaţie: Dacă X şi Y sunt v.a. independente, atunci

$$p_{ij} = P(X = x_i, Y = y_j) = P(X = x_i)P(Y = y_j) \quad \forall\ i \in I, j \in J. \tag{1}$$

▷ Dacă X şi Y sunt v.a. independente, şi se ştiu distribuţiile lor, atunci distribuţia vectorului aleator (X, Y) se determină pe baza formulei (1).
▷ Dacă se cunoaşte distribuţia vectorului aleator (X, Y) distribuţiile lui X şi Y se determină astfel:

$$P(X = x_i) = \sum_{j \in J} p_{ij} \quad \forall i \in I, \qquad P(Y = y_j) = \sum_{i \in I} p_{ij} \quad \forall j \in J.$$

Operaţii cu variabile aleatoare (numerice)

Exemplu: Fie vectorul aleator discret (X, Y) cu distribuţia dată de următorul tabel:

X \ Y	0	1	2
1	$\frac{2}{16}$	$\frac{1}{16}$	$\frac{2}{16}$
2	$\frac{1}{16}$	$\frac{5}{16}$	$\frac{5}{16}$

. Determinaţi: a) distribuţiile variabilelor aleatoare X şi Y;
b) distribuţiile variabilelor aleatoare $X + Y$ şi $X \cdot Y$, $X^2 - 1$;
c) dacă variabilele aleatoare X şi Y sunt independente sau dependente.

Exerciţii: (1) Fie X,Y v.a. independente, având distribuţiile

$$X \sim \begin{pmatrix} 0 & 1 \\ \frac{1}{3} & \frac{2}{3} \end{pmatrix}, \quad Y \sim \begin{pmatrix} -1 & 0 & 1 \\ \frac{1}{2} & \frac{1}{4} & \frac{1}{4} \end{pmatrix}$$

a) Care sunt distribuţiile v.a. $2X + 1$, Y^2, dar distribuţia vectorului aleator (X, Y)?
b) Care sunt distribuţiile v.a. $X + Y$, $X \cdot Y$, $\max(X, Y)$, $\min(X, Y^2)$?
(2) Într-o echipă de dezvoltare software s-au implementat un set (o colecţie) de 100 de teste independente, care verifică funcţionalitatea unei noi aplicaţii. Aceste teste sunt rulate de fiecare dată când se face o modificare în cod. Pe baza datelor statistice existente, s-a constatat că fiecare test are o probabilitate de 95% să treacă (adică să nu detecteze o eroare). Pentru a estima fiabilitatea sistemului, se doreşte modelarea probabilităţii ca un anumit număr de teste să treacă într-o execuţie completă a setului de teste. (a) Care este probabilitatea ca exact 95 de teste să treacă? (b) Probabilitatea ca cel puţin 90 de teste să treacă? (c) Dacă X este numărul de teste care trec, să se calculeze $P(X > 95)$? (d) Ce descrie variabila aleatoare $100 - X$? ♣

Clasificarea naivă Bayes

În învăţarea automată, clasificatorii bayesieni naivi sunt o familie de clasificatori probabilistici simpli, bazaţi pe aplicarea formulei lui Bayes (a se vedea P.5) cu ipoteze „naive" de independenţă condiţionată între atribute (engl. *features*), cunoscând clasificarea. Pentru unele tipuri de modele de probabilitate, clasificatorii bayesieni naivi pot fi antrenaţi foarte eficient. În aplicaţii practice pentru modelele bayesiene naive se foloseşte *metoda probabilităţii maxime*.

Fie $(\Omega, \mathcal{K}, P)$ un spaţiu de probabilitate. De asemenea considerăm că toate probabilităţile condiţionate sunt definite (adică condiţionarea se face în raport cu un eveniment a cărui probabilitate nu este 0).

Def. 13. *Fie X, Y, Z v.a. discrete, care iau valori în mulţimile $\mathcal{X}$, $\mathcal{Y}$, $\mathcal{Z}$. V.a. X este* ***condiţionat independentă*** *de Y, cunoscând (ştiind) v.a. Z, dacă pentru fiecare $x \in \mathcal{X}, y \in \mathcal{Y}, z \in \mathcal{Z}$,are loc*

$$P(X = x, Y = y | Z = z) = P(X = x | Z = z) P(Y = y | Z = z)\,.$$

Exemplu de clasificare naivă Bayes

	Vreme	*Timp*	**Trafic**
1	înnorat	noapte	**relaxat**
2	zăpadă	seară	**aglomerat**
3	senin	noapte	**relaxat**
4	ploaie	seară	**aglomerat**
5	înnorat	amiază	**aglomerat**
6	senin	amiază	**aglomerat**
7	senin	dimineaţă	**relaxat**
8	ploaie	noapte	**relaxat**
9	înnorat	dimineaţă	**aglomerat**
10	zăpadă	noapte	**aglomerat**
11	senin	seară	**relaxat**
12	zăpadă	amiază	**relaxat**
13	înnorat	seară	**aglomerat**
14	ploaie	dimineaţă	**aglomerat**
15	zăpadă	dimineaţă	**aglomerat**
16	**ploaie**	**amiază**	**?**

Tabel de date obţinute în urma unor observaţii

Se doreşte *clasificarea* **traficului** $\boldsymbol{T}$ pe un anumit bulevard, în *clasele*: *aglomerat* $\boldsymbol{a}$ sau *relaxat* $\boldsymbol{r}$, în funcţie de următoarele *atribute* cu valorile lor posibile:

• **vreme** $\boldsymbol{V}$: ploaie p, zăpadă z, senin s, înnorat $\hat{\imath}$ (dar nu plouă şi nu ninge) ;

• **timp** $\boldsymbol{Ti}$: dimineaţă di, amiază am, seară se, noapte no.

Considerăm evenimentul următor, denumit *vector de atribute*:

$$E = (\boldsymbol{V = p}) \cap (\boldsymbol{Ti = am}).$$

Se caută o clasă pentru E, stabilind care din următoarele probabilităţi este mai mare: $P(\boldsymbol{T = a}|E)$ sau $P(\boldsymbol{T = r}|E)$; aceasta este **metoda de probabilitate maximă.** *Ştiind că vremea este ploioasă şi este amiază, ce previziune se poate face despre trafic (aglomerat* $\boldsymbol{a}$ *sau relaxat* $\boldsymbol{r}$*)*?

Se face următoarea presupunere *naivă*: atributele sunt **condiţional independente**, dacă se ştie (cunoaşte) clasificarea, adică

$$P(V = v, Ti = ti|\mathbf{T} = \mathbf{t}) = P(V = v|\mathbf{T} = \mathbf{t})P(Ti = ti|\mathbf{T} = \mathbf{t}), \tag{2}$$

pentru fiecare $v \in \{p, z, s, \hat{\imath}\}$, $ti \in \{di, am, se, no\}$, $\mathbf{t} \in \{\mathbf{a}, \mathbf{r}\}$. De exemplu, avem:

$$P(V = p, Ti = di|\mathbf{T} = \mathbf{a}) = P(V = p|\mathbf{T} = \mathbf{a})P(Ti = di|\mathbf{T} = \mathbf{a}).$$

► Folosind datele din tabel, determinăm mai întâi probabilităţile claselor şi probabilităţile condiţionate ale atributelor, cunoscând clasa.

$\mathbf{T} = \mathbf{a}$	$\mathbf{T} = \mathbf{r}$	$P(\mathbf{T} = \mathbf{a})$	$P(\mathbf{T} = \mathbf{r})$
9	6	$\frac{9}{15}$	$\frac{6}{15}$

V	$\mathbf{T} = \mathbf{a}$	$\mathbf{T} = \mathbf{r}$	$P(V = ...\|\mathbf{T} = \mathbf{a})$	$P(V = ...\|\mathbf{T} = \mathbf{r})$
p	2	1	$\frac{2}{9}$	$\frac{1}{6}$
z	3	1	$\frac{3}{9}$	$\frac{1}{6}$
s	1	3	$\frac{1}{9}$	$\frac{3}{6}$
$\hat{\imath}$	3	1	$\frac{3}{9}$	$\frac{1}{6}$

Ti	$\mathbf{T} = \mathbf{a}$	$\mathbf{T} = \mathbf{r}$	$P(Ti = ...\|\mathbf{T} = \mathbf{a})$	$P(Ti = ...\|\mathbf{T} = \mathbf{r})$
di	3	1	$\frac{3}{9}$	$\frac{1}{6}$
am	2	1	$\frac{2}{9}$	$\frac{1}{6}$
se	3	1	$\frac{3}{9}$	$\frac{1}{6}$
no	1	3	$\frac{1}{9}$	$\frac{3}{6}$

▶ Pe baza formulei lui Bayes P. 5 şi a ipotezei de independenţă condiţionată, deducem că:

$$P(\mathbf{T}=\mathbf{a}|E)=\frac{P(E|\mathbf{T}=\mathbf{a})P(\mathbf{T}=\mathbf{a})}{P(E)}=\frac{P(V=p,Ti=am|\mathbf{T}=\mathbf{a})P(\mathbf{T}=\mathbf{a})}{P(E)}$$

$$=\frac{P(V=p|\mathbf{T}=\mathbf{a})P(Ti=am|\mathbf{T}=\mathbf{a})P(\mathbf{T}=\mathbf{a})}{P(E)}=\frac{\frac{2}{9}\cdot\frac{2}{9}\cdot\frac{9}{15}}{P(E)}=\frac{1}{P(E)}\cdot\frac{4}{135}$$

şi

$$P(\mathbf{T}=\mathbf{r}|E)=\frac{P(E|\mathbf{T}=\mathbf{r})P(\mathbf{T}=\mathbf{r})}{P(E)}=\frac{P(V=p,Ti=am|\mathbf{T}=\mathbf{r})P(\mathbf{T}=\mathbf{r})}{P(E)}$$

$$=\frac{P(V=p|\mathbf{T}=\mathbf{r})P(Ti=am|\mathbf{T}=\mathbf{r})P(\mathbf{T}=\mathbf{r})}{P(E)}=\frac{\frac{1}{6}\cdot\frac{1}{6}\cdot\frac{6}{15}}{P(E)}=\frac{1}{P(E)}\cdot\frac{1}{90}.$$

Deoarece $P(\mathbf{T}=\mathbf{a}|E)>P(\mathbf{T}=\mathbf{r}|E)$, asociem vectorului de atribute

$$E=(V=p)\cap(Ti=am) \text{ clasa } \mathbf{T}=\mathbf{a}.$$

▶ În plus, putem determina $P(E)=P(V=p,Ti=am)$ astfel: Scriem

$$1=P(\mathbf{T}=\mathbf{a}|E)+P(\mathbf{T}=\mathbf{r}|E)=\frac{1}{P(E)}\left(\frac{4}{135}+\frac{1}{90}\right)$$

şi deducem $P(E)=P(V=p,Ti=am)=\frac{11}{270}\approx 0.04$. ✸

Valoarea medie a unor variabile aleatoare discrete

Def. 14. ***Valoarea medie a unei variabile aleatoare discrete*** *(numerice) X, care ia valorile $\{x_i, i \in I\}$, este*

$$E(X) = \sum_{i \in I} x_i P(X = x_i),$$

dacă $\sum_{i \in I} |x_i| P(X = x_i) < \infty$.

▷ Valoarea medie a unei variabile aleatoare caracterizează *tendinţa centrală* a valorilor acesteia.

P. 8. *Fie X şi Y v.a. discrete. Au loc proprietăţile:*
→ $E(aX + b) = aE(X) + b$ *pentru orice* $a, b \in \mathbb{R}$;
→ $E(X + Y) = E(X) + E(Y)$;
→ *Dacă X şi Y sunt v.a. independente, atunci* $E(X \cdot Y) = E(X)E(Y)$.
→ *Dacă* $g : \mathbb{R} \to \mathbb{R}$ *e o funcţie astfel încât* $g(X)$ *este v.a., atunci*

$$E(g(X)) = \sum_{i \in I} g(x_i) P(X = x_i),$$

dacă $\sum_{i \in I} |g(x_i)| P(X = x_i) < \infty$.

➤ Python: `numpy.mean`$(x) = \frac{1}{n}(x_0 + ... + x_{n-1})$ pentru $x = [x_0, ..., x_{n-1}]$
➤ Fie $x = [x_0, \ldots, x_{n-1}]$ valori aleatoare ale unei v.a. X, atunci

$$E(X) \approx \texttt{numpy.mean}(x) = \frac{1}{n}(x_0 + \cdots + x_{n-1}) \text{ pentru } n \text{ suficient de mare}$$

```
# Exemplu numpy.mean
import numpy
x = [[1, 3], [5, 9]]
print("media aritmetica (toate elementele):",numpy.mean(x))
print("media aritmetica (pe coloane):", numpy.mean(x, axis=0))
print("media aritmetica (pe linii):", numpy.mean(x, axis=1))
y=[-1,0,-2,0,1,2,2,1,0,1,2,2,1,0,-1,0]
print("media aritmetica (vector):",numpy.mean(y))
```

Exemplu: Joc: Se aruncă un zar; dacă apare 6, se câştigă 3 u.m. (unităţi monetare), dacă apare 1 se câştigă 2 u.m., dacă apare 2,3,4,5 se pierde 1 u.m. În medie cât va câştiga sau pierde un jucător după 30 de repetiţii ale jocului?
Răspuns: Fie X v.a. care indică venitul la un joc

$$X \sim \begin{pmatrix} -1 & 2 & 3 \\ \frac{4}{6} & \frac{1}{6} & \frac{1}{6} \end{pmatrix}$$

Pentru $i \in \{1, ..., 30\}$ fie X_i venitul la al i-lea joc; X_i are aceeaşi distribuţie ca X. Venitul mediu al jucătorului după 30 de repetiţii ale jocului este

$$E(X_1 + ... + X_{30}) = E(X_1) + ... + E(X_{30}) = 30 \cdot E(X) = 30 \cdot \frac{1}{6} \cdot (2 - 4 + 3) = 5 \text{ (u.m.)}.$$

Aşadar jucătorul *câştigă în medie* 5 u.m.

```
import numpy as np
s=[]
N=10000
for _ in range(N):
    jocuri = np.random.choice([-1,-1,-1,-1,2,3],size=30,replace=True)
    s.append(sum(jocuri))
print("Castigul mediu (dupa 30 jocuri):",numpy.mean(s))
```

Exerciţiu: Variabila aleatoare X descrie de câte ori apare pana de curent în reţea (pe parcursul unei zile, într-o anumită localitate)

$$P(X=0)=0.9, P(X=1)=0.08, P(X=2)=0.02\,.$$

O companie de comerţ pe internet estimează că fiecare astfel de pană de curent în reţea duce la o pierdere de 200 Ron. Calculaţi valoarea medie a pierderilor zilnice ale acestei companii (datorate lipsei de curent). Estimaţi această valoare medie cu ajutorul unor simulări în Python.

Funcţia de repartiţie a unei variabile aleatoare discrete

Def. 15. ***Funcţia de repartiţie*** $F:\mathbb{R}\to[0,1]$ *a unei variabile aleatoare discrete* X*, care ia valorile* $\{x_i, i\in I\}$*, este*

$$F(x)=P(X\le x)=\sum_{i\in I: x_i\le x} P(X=x_i)\quad \forall x\in\mathbb{R}.$$

În lb. engleză denumirea este `cummulative distribution function`, prescurtat cu `cdf`.

Exemplu: Funcţia de repartiţie $F_X:\mathbb{R}\to[0,1]$ a v.a. discrete X este

$$F_X(x)=P(X\le x)=\begin{cases}0, & \text{dacă } x<-2\\ 0.5, & \text{dacă } -2\le x<1\\ 0.7, & \text{dacă } 1\le x<2\\ 1, & \text{dacă } 2\le x\,.\end{cases}$$

Determinaţi valoarea medie a lui X. ♣

P. 9. *Funcţia de repartiţie* F *a unei variabile aleatoare discrete* X *are următoarele proprietăţi:*
(1) $F(b)-F(a)=P(X\le b)-P(X\le a)=P(a<X\le b)\ \forall a,b\in\mathbb{R}, a<b.$
(2) F *este monoton crescătoare, adică pentru orice* $x_1<x_2$ *rezultă* $F(x_1)\le F(x_2)$.
(3) F *este continuă la dreapta, adică* $\lim\limits_{x\searrow x_0} F(x)=F(x_0)\ \forall\, x_0\in\mathbb{R}.$
(4) $\lim\limits_{x\to\infty} F(x)=1$ *şi* $\lim\limits_{x\to-\infty} F(x)=0.$

Observaţii:
▷ Funcţia de repartiţie a unei v.a. descrie complet comportamentul probabilistic al acelei v.a.
➤ în Python: se calculează $F(x)=P(X\le x)$
pentru $X\sim Bino(n,p)$ cu `scipy.stats.binom.cdf`(x,n,p),
pentru $X\sim Hyge(n,n_1,n_2)$ cu `scipy.stats.hypergeom.cdf`(x,n_1+n_2,n_1,n).

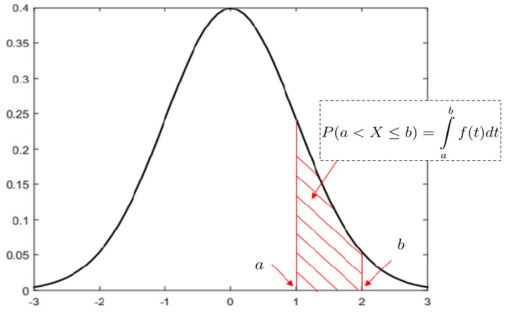
```
#Fie o urna cu 10 bile, din care 5 sunt rosii; X (v.a.)= cate bile rosii au fost extrase
#in 5 extrageri cu returnare; se reprezinta grafic functia de repartitie a lui X
import scipy.stats
import matplotlib.pyplot as plt
import numpy as np
n=5
```

```
p=0.5
x = np.linspace(-2, n+2, 101)
y=scipy.stats.binom.cdf(x,n,p)
plt.plot(x, y, "r.")
for t in range(n+1):
    plt.plot(t, scipy.stats.binom.cdf(t,n,p), "ko")
    plt.plot(t, scipy.stats.binom.cdf(t-(n+4)/100,n,p), 'ko', mfc='none')
plt.xlabel("x")
plt.ylabel("F(x)=P(X <= x)")
plt.title("Functia de repartitie a lui X")
plt.xticks(range(-2,n+3))
plt.grid()
plt.show()
```

Variabile aleatoare continue

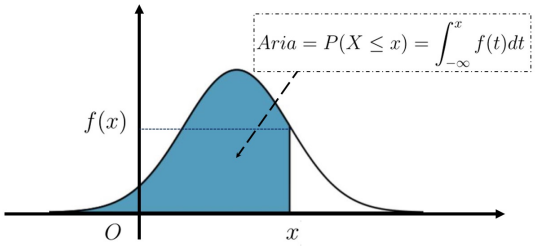
V.a. continuă: ia un număr infinit şi nenumărabil de valori într-un interval sau reuniune de intervale (v.a. poate lua orice valoare din intervalul considerat); ▷ v.a. continue pot modela caracteristici fizice (măsurabile) precum timp (de ex. timp de instalare, timp de aşteptare), greutate, lungime, poziţie, volum, temperatură (de ex. X e v.a. care indică durata de funcţionare a unui dispozitiv până la prima defectare; X e v.a. care indică temperatura într-un oraş la ora amiezii)

▷ v.a. continuă este caracterizată de funcţia de densitate.



Def. 16. ***Funcţia de densitate*** *a unei v.a. continue X este funcţia $f : \mathbb{R} \to \mathbb{R}$ pentru care are loc*

$$P(X \leq x) = \int_{-\infty}^{x} f(t)dt\,,\ \forall\, x \in \mathbb{R}.$$



Funcţia $F : \mathbb{R} \to [0, 1]$ definită prin

$$F(x) = P(X \leq x) = \int_{-\infty}^{x} f(t)dt,\ \forall\, x \in \mathbb{R},$$

se numeşte ***funcţia de repartiţie*** *a v.a. continue X.*

P. 10. *Fie f funcţia de densitate şi F funcţia de repartiţie a unei v.a. continue X. Au loc proprietăţile:*

(1) $f(t) \geq 0$ *pentru orice* $t \in \mathbb{R}$;

(2) $\int_{-\infty}^{\infty} f(t)\,dt = 1$;

(3) $F(b) - F(a) = P(a < X \leq b) = \int_a^b f(t)dt\ \forall\, a, b \in \mathbb{R}, a < b$;

(4) $P(X = a) = 0\ \ \forall\, a \in \mathbb{R}$;

(5) $P(X \in M) = \int_M f(t)dt,\ M \subseteq \mathbb{R}$ *pentru care integrala există;*

(6) *pentru* $\forall\, a < b,\ a, b \in \mathbb{R}$ *au loc*

$$F(b) - F(a) = P(a \leq X \leq b) = P(a < X \leq b) = P(a \leq X < b) = P(a < X < b) = \int_a^b f(t)dt;$$

(7) *F este o funcţie monoton crescătoare şi continuă pe $\mathbb{R}$;*
(8) $\lim_{x\to\infty} F(x) = 1$ *şi* $\lim_{x\to-\infty} F(x) = 0$.
(9) *dacă F este derivabilă în punctul x, atunci $F'(x) = f(x)$.*

Observaţii: (1) Orice funcţie $f : \mathbb{R} \to \mathbb{R}$, care are proprietăţile (1), (2) din **P.10** este o funcţie de densitate.
(2) Fie f_1 o funcţie de densitate pentru v.a. X şi fie $f_2 : \mathbb{R} \to \mathbb{R}$ astfel încât $f_1(t) = f_2(t)$ pentru orice $t \in \mathbb{R} \setminus \mathcal{N}$, unde $\mathcal{N}$ este o mulţime *cel mult numărabilă*. Atunci f_2 este o funcţie de densitate pentru aceeaşi v.a. X. Este suficient să cunoaştem o funcţie de densitate în orice punct din $\mathbb{R}$ exceptând, eventual, o mulţime cel mult numărabilă de puncte. Funcţia de densitate asociată unei v.a. nu este unică (unicitate în sensul egalităţii în toate punctele din $\mathbb{R}$). Proprietăţile integralelor implică

$$\int_{-\infty}^{x} f_1(t)dt = \int_{-\infty}^{x} f_2(t)dt, \ \forall\, x \in \mathbb{R},$$

$$\int_{a}^{b} f_1(t)dt = \int_{a}^{b} f_2(t)dt, \forall\, a < b, \ a, b \in \mathbb{R}.$$

(3) *Funcţia de fiabilitate* (sau funcţia de supravieţuire) este folosită în studiul fiabilităţii unor a sisteme, şi a duratei de funcţionare până la prima defecţiune

$$R(x) = P(X > x), \ x \in \mathbb{R}$$

Exemple de distribuţii clasice continue

➦**Distribuţia uniformă pe un interval $[a, b]$:** $X \sim Unif[a, b]$, $a, b \in \mathbb{R}$, $a < b$

• funcţia de densitate este

$$f(t) = \begin{cases} \dfrac{1}{b-a}, \text{pentru } t \in [a, b] \\ 0, \ \text{pentru } t \in \mathbb{R} \setminus [a, b] \end{cases}$$

Python:
▷ pentru $a = 0, b = 1$: `random.random()` returnează o valoare aleatoare din $[0, 1]$
▷ `scipy.stats.uniform.rvs`$(a, b - a,$ `size` $= N)$ returnează N valori aleatoare uniform distribuite din $[a, b]$



Friedrich Gauss (1777-1855) şi legea normală $N(\mu, \sigma^2)$ (bancnota de 10 DM)

➦ **Distribuţia normală (Gauss):** $X \sim N(\mu, \sigma^2)$, $\mu \in \mathbb{R}$, $\sigma > 0$

• funcţia de densitate este

$$f(t) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(t-\mu)^2}{2\sigma^2}}, t \in \mathbb{R}.$$

• Pentru $\mu = 0, \sigma = 1$: $N(0,1)$ se numeşte *distribuţia standard normală.*

• Distribuţia normală se aplică în: măsurarea erorilor (de ex. termenul eroare în analiza regresională), în statistică (teorema limită centrală, teste statistice) etc.

```
# Distributia normala: densitate si functie de repartitie
import matplotlib.pyplot as plt
import numpy as np
from scipy.stats import norm
x = np.linspace(-8, 8, 1001)
sigma = [1, 2, 4]
mu= 0
fig, ax = plt.subplots(1, 2, figsize=(12, 4))
for t in sigma:
    # scale= deviatia standard (sigma), loc = media (mu)
    f = norm.pdf(x, loc=mu, scale=t)
    F = norm.cdf(x, loc=mu, scale=t)
    ax[0].plot(x, f, label=f"N(0,{t}$^2$)")
    ax[1].plot(x, F, label=f"N(0,{t}$^2$)")
# Graficul densitatii
ax[0].set_xlabel("x")
ax[0].set_ylabel("f(x)")
ax[0].set_title("Functia de densitate")
ax[0].grid(True)
ax[0].legend()
# Graficul functiei de repartitie
ax[1].set_xlabel("x")
ax[1].set_ylabel("F(x)")
ax[1].set_title("Functia de repartitie")
ax[1].grid(True)
ax[1].legend()
plt.suptitle("Distributia normala")
plt.tight_layout()
plt.show()
```

➡**Distribuţia exponenţială:** $X \sim Exp(\lambda), \lambda > 0$

• funcţia de densitate este

$$f(t) = \begin{cases} \lambda e^{-\lambda t}, & \text{pentru } t > 0 \\ 0, & \text{pentru } t \leq 0 \end{cases}$$

```
# functia de densitate pentru distributia exponentiala
import matplotlib.pyplot as plt
import numpy as np
from scipy.stats import expon
x = np.linspace(0, 4, 100)
L= [1, 2, 3]  # valori pentru Lambda
for t in L:
    y = expon.pdf(x, scale=1/t)
    plt.plot(x, y, label=f"Exp({t})")
plt.xlabel("x")
plt.ylabel("functia de densitate")
plt.title("Distributia exponentiala")
plt.legend()
```

```
plt.show()
```

➦**Distribuţia Student:** $X \sim T(n), n \in \mathbb{N}^*$

• distribuţia Student cu $n \in \mathbb{N}^*$ grade de libertate are funcţia de densitate

$$f(x) = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{n\pi}\Gamma\left(\frac{n}{2}\right)}\left(1+\frac{x^2}{n}\right)^{-\frac{n+1}{2}}, \ x \in \mathbb{R}$$

unde funcţia Gamma este

$$\Gamma(a) = \int_0^\infty t^{a-1}\exp(-t)dt, \ a > 0$$

```
#Exemplu functii de densitate
import matplotlib.pyplot as plt
import numpy as np
from scipy.stats import t,norm
x = np.linspace(-5, 5, 100)
degrees_of_freedom = [1, 2, 5]
# diferite grade de libertate pt distributia Student T(.)
# functii de densitate
for df in degrees_of_freedom:
    y = t.pdf(x, df)
    plt.plot(x, y, label=f"T({df})")
z0=norm.pdf(x,0,1)
plt.plot(x, z0, label="N(0,1)")
plt.xlabel('x')
plt.ylabel("functia de densitate")
plt.title("distributia Student si distributia normala standard")
plt.legend()
plt.show()
```

➦**Distribuţia Chi-pătrat:** $X \sim \chi^2(n), n \in \mathbb{N}^*$

• distribuţia χ^2 cu $n \in \mathbb{N}^*$ grade de libertate are funcţia de densitate

$$f(x) = \begin{cases} 0, & \text{dacă } x \leq 0 \\ \dfrac{1}{\Gamma(\frac{n}{2})2^{\frac{n}{2}}} \cdot x^{\frac{n}{2}-1} \cdot \exp\left(-\dfrac{x}{2}\right), & \text{dacă } x > 0, \end{cases}$$

Exemplu 11. Fie $X \sim Exp(0.5)$ v.a. care indică timpul de funcţionare a unei baterii (câte luni funcţionează bateria). Să se calculeze a) $P(2 \leq X \leq 4)$; b) $P(X > 3)$.

R: $P(2 \leq X \leq 4) = \int_2^4 0.5e^{-0.5t}dt = -e^{-0.5t}\Big|_2^4 = e^{-1} - e^{-2} \approx 0.23254$

$$P(X > 3) = 1 - \int_{-\infty}^3 0.5e^{-0.5t}dt = \int_3^\infty 0.5e^{-0.5t}dt = -e^{-0.5t}\Big|_3^\infty = e^{-1.5} \approx 0.22313 \quad \clubsuit$$

Exerciţiu: Fie X v.a. care indică timpul de funcţionare neîntreruptă (în ore) până la prima defectare a unui aparat, pentru care $P(X > x) = 2^{-x}, x > 0$ şi $P(X > x) = 1, x \leq 0$. Să se determine f_X şi $P(2 < X < 3)$.

Vector aleator

► $(X_1, \ldots, X_n)$ este un **vector aleator discret** dacă fiecare componentă a sa este o variabiă aleatoare discretă.
► $(X_1, \ldots, X_n)$ este un **vector aleator continuu** dacă fiecare componentă a sa este o variabiă aleatoare continuă.

Def. 17. $F_{(X,Y)} : \mathbb{R} \times \mathbb{R} \to \mathbb{R}_+$ *este* ***funcţia de repartiţie a vectorului aleator*** (X, Y) *(discret sau continuu), dacă*

$$F_{(X,Y)}(x, y) = P(X \leq x, Y \leq y) \quad \forall\, x, y \in \mathbb{R}.$$

► Dacă se cunoaşte funcţia de repartiţie $F_{(X,Y)}$ pentru vectorul aleator (X, Y) (discret sau continuu), atunci F_X, respectiv F_Y, se determină cu

(3) $$F_X(x) = \lim_{y \to \infty} F_{(X,Y)}(x, y), \quad F_Y(y) = \lim_{x \to \infty} F_{(X,Y)}(x, y).$$

F_X şi F_Y se numesc **funcţii de repartiţie marginale**.

Def. 18. X *şi* Y *sunt* ***variabile aleatoare independente*** *(discrete sau continue), dacă şi numai dacă*

$$P(X \leq x, Y \leq y) = P(X \leq x)P(Y \leq y)\ \forall\, x, y \in \mathbb{R},$$

ceea ce este echivalent cu

$$F_{(X,Y)}(x, y) = F_X(x) \cdot F_Y(y) \quad \forall\, x, y \in \mathbb{R}.$$

Exerciţiu: Funcţia de repartiţie a vectorului aleator (X, Y) este $F_{(X,Y)} : \mathbb{R} \times \mathbb{R} \to [0, 1]$

$$F_{(X,Y)}(x, y) = \begin{cases} 0, & \text{dacă } x < 0 \text{ sau } y < 1 \\ x(y-1), & \text{dacă } 0 \leq x < 1 \text{ şi } 1 \leq y < 2 \\ x, & \text{dacă } 0 \leq x < 1 \text{ şi } 2 \leq y \\ y - 1, & \text{dacă } 1 \leq x \text{ şi } 1 \leq y < 2 \\ 1, & \text{dacă } 1 \leq x \text{ şi } 2 \leq y\,. \end{cases}$$

Sunt X şi Y v.a. independente? Determinaţi f_X, respectiv f_Y. ♣

Valoarea medie a unei variabile aleatoare continue

Def. 19. ***Valoarea medie a unei v.a. continue*** X*, care are funcţia de densitate* f*, este*

$$E(X) = \int_{-\infty}^{\infty} t f(t)dt, \text{ dacă } \int_{-\infty}^{\infty} |t| f(t)dt < \infty.$$

▷ Valoarea medie a unei variabile aleatoare caracterizează tendinţa centrală a valorilor acesteia.

P. 11. *Proprietăţi ale valorii medii: fie* X, Y *v.a. continue:*
→ $E(aX + b) = aE(X) + b$ *pentru orice* $a, b \in \mathbb{R}$.
→ $E(X + Y) = E(X) + E(Y)$.
→ *Dacă* X *şi* Y *sunt variabile aleatoare* ***independente****, atunci* $E(X \cdot Y) = E(X)E(Y)$.
→ *Dacă* $g : \mathbb{R} \to \mathbb{R}$ *e o funcţie, astfel încât* $g(X)$ *este o v.a. continuă, atunci*

$$E(g(X)) = \int_{-\infty}^{\infty} g(t) f_X(t)dt,$$

dacă $\int_{-\infty}^{\infty} |g(t)| f_X(t)dt < \infty$.

Exemplu: Durata drumului parcurs de un elev dimineaţa de acasă până la şcoală este o v.a. uniform distribuită între 20 şi 26 minute. Dacă elevul porneşte la 7:35 (a.m.) de acasă şi are ore de la 8 (a.m.), care este probabilitatea ca elevul să ajungă la timp la şcoală? *În medie* cât durează drumul elevului până la şcoală?
R.: Fie X (v.a.) = durata drumului parcurs până la şcoală (în minute) $\Rightarrow X \sim Unif[20, 26]$

$$\Longrightarrow f_X(t) = \begin{cases} \frac{1}{26-20} = \frac{1}{6}, & \text{dacă } 20 \leq t \leq 26 \\ 0, & \text{în rest.} \end{cases}$$

$$P(\text{“elevul ajunge la timp la şcoală”}) = P(X \leq 25) = \int_{-\infty}^{25} f_X(t)dt = \int_{20}^{25} \frac{1}{6}dt = \frac{25-20}{6} = \frac{5}{6}.$$

$$E(X) = \int_{-\infty}^{\infty} t f_X(t)dt = \int_{20}^{26} t \cdot \frac{1}{6}dt = \frac{1}{6} \cdot \frac{t^2}{2}\Big|_{20}^{26} = 23 \text{ (minute)}.$$

♣

Varianţa unei variabile aleatoare

Def. 20. ***Varianţa (dispersia)*** *unei variabile aleatoare X (discrete sau continue) este*

$$V(X) = E\left((X - E(X))^2\right),$$

(dacă valoarea medie $E\left((X - E(X))^2\right)$ există). Valoarea $\sqrt{V(X)}$ se numeşte ***deviaţia standard*** *a lui X şi o notăm cu $Std(X)$.*

▶ Varianţa unei variabile aleatoare caracterizează împrăştierea (dispersia) valorilor lui X în jurul valorii medii $E(X)$.

P. 12. *Proprietăţi ale varianţei (pentru v.a. discrete sau continue):*
$\rightarrow V(X) = E(X^2) - E^2(X)$.
$\rightarrow V(aX + b) = a^2V(X)\ \forall\ a, b \in \mathbb{R}$.
$\rightarrow$ *Dacă X şi Y sunt variabile aleatoare* ***independente****, atunci*

$$V(X + Y) = V(X) + V(Y).$$

▶ Python: `numpy.mean, numpy.var, numpy.std`
Fie $x = [x_0, \ldots, x_{n-1}]$ valori aleatoare ale unei v.a. X

$$E(X) \approx \texttt{numpy.mean}(x) = \frac{1}{n}(x_0 + \cdots + x_{n-1}) \text{ pentru } n \text{ suficient de mare}$$

$$V(X) \approx \texttt{numpy.var}(x) = \frac{1}{n}\sum_{i=0}^{n-1}(x_i - \texttt{numpy.mean}(x))^2 \text{ pentru } n \text{ suficient de mare}$$

$$Std(X) \approx \texttt{numpy.std}(x) = \left(\frac{1}{n}\sum_{i=0}^{n-1}(x_i - \texttt{numpy.mean}(x))^2\right)^{\frac{1}{2}} \text{pentru } n \text{ suficient de mare .}$$

Observaţie: Dacă Z este o v.a. (cu $V(Z) > 0$) atunci v.a. $\tilde{Z} := \frac{Z - E(Z)}{Std(Z)}$ este **versiunea standardizată** a v.a. Z, iar $E(\tilde{Z}) = 0$ şi $V(\tilde{Z}) = 1$.

Proprietăţi (recapitulare)

V.a. discretă	V.a. continuă
• caracterizată de distribuţia de probabilitate discretă $X \sim \begin{pmatrix} x_i \\ P(X=x_i) \end{pmatrix}_{i\in I}$	• caracterizată de funcţia de densitate f $P(X \le x) = \int_{-\infty}^{x} f(t)dt$
• $\sum_{i\in I} P(X=x_i) = 1$	• $\int_{-\infty}^{\infty} f(t)dt = 1$
• $P(X \in A) = \sum_{i\in I:\, x_i\in A} P(X=x_i)$	• $P(X \in A) = \int_A f(t)dt$
• funcţia de repartiţie $F(x)=P(X \le x)\ \forall x \in \mathbb{R}$	• funcţia de repartiţie $F(x)=P(X \le x)\ \forall x\in\mathbb{R}$
• $F(x) = \sum_{i\in I:\, x_i\le x} P(X=x_i)\ \forall x \in \mathbb{R}$	• $F(x) = \int_{-\infty}^{x} f(t)dt \quad \forall x \in \mathbb{R}$
• F este funcţie monoton crescătoare	• F este funcţie monoton crescătoare
• F este funcţie continuă la dreapta	• F este funcţie continuă în orice punct $x \in \mathbb{R}$
• F este discontinuă în punctele $x_i,\ \forall\, i \in I$	
• $\forall\, a < b, a, b \in \mathbb{R}$ $P(a \le X \le b) = \sum_{i\in I: a\le x_i\le b} P(X=x_i)$	• $\forall\, a < b, a, b \in \mathbb{R}$ $P(a \le X \le b) = \int_a^b f(t)\,dt$
• $P(X=a) = 0$ dacă $a \notin \{x_i : i \in I\}$	• $P(X=a) = \int_a^a f(t)\,dt = 0\ \forall\, a \in \mathbb{R}$
	• dacă F este derivabilă în punctul x $\Rightarrow\ F'(x) = f(x)$
• valoarea medie $E(X) = \sum_{i\in I} x_i P(X=x_i)$	• valoarea medie $E(X) = \int_{-\infty}^{\infty} t f(t)\,dt.$

Exemple: 1) Fie $X \sim Bino(n,p)$. Să se arate că $E(X) = np$ şi $V(X) = np(1-p)$.
R.: Pentru $i \in \{1,\dots,n\}$ fie $X_i \sim Bernoulli(p)$ (adică $P(X_i = 1) = p$, $P(X_i = 0) = 1-p$), astfel încât $X_1,\dots,X_n$ sunt v.a. independente. Observăm că $X_1 + \dots + X_n \sim Bino(n,p)$. Deci, $X_1 + \dots + X_n$ şi X au aceeaşi distribuţie, aşadar ele au aceeaşi valoare medie şi aceeaşi varianţă

$$E(X) = E(X_1 + \cdots + X_n) = E(X_1) + \cdots + E(X_n) = p + \dots + p = np.$$

V.a. $X_1,\dots,X_n$ sunt independente şi folosind P.12, obţinem

$$V(X) = V(X_1 + \cdots + X_n) = V(X_1) + \cdots + V(X_n) = np(1-p) = np(1-p).$$

2) Dacă $X \sim N(\mu,\sigma^2)$ să se arate că $E(X) = \mu,\ V(X) = \sigma^2$.
R.: Funcţia de densitate a lui X este

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\}, x \in \mathbb{R}.$$

Când $\mu = 0$ şi $\sigma = 1$ obţinem *funcţia de densitate a distribuţiei normale standard*

$$\varphi(x) = \frac{1}{\sqrt{2\pi}} \exp\left\{-\frac{x^2}{2}\right\}, x \in \mathbb{R}.$$

Din P.10-(2) rezultă

$$\int_{-\infty}^{\infty} \varphi(t)dt = 1.$$

În calculele de mai jos utilizăm schimbarea de variabilă $t = \dfrac{x-\mu}{\sigma}$

$$\begin{aligned} E(X) = \int_{-\infty}^{\infty} x f_X(x)dx &= \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^{\infty} x \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\} dx \\ &= \frac{\sigma}{\sqrt{2\pi}} \int_{-\infty}^{\infty} t \exp\left\{-\frac{t^2}{2}\right\} dt + \mu \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} \exp\left\{-\frac{t^2}{2}\right\} dt \\ &= 0 + \mu \int_{-\infty}^{\infty} \varphi(t)dt = \mu\,. \end{aligned}$$

Folosind aceeaşi schimbare de variabilă şi apoi integrare prin părţi, avem

$$\begin{aligned} V(X) &= E[(X-\mu)^2] = \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^{\infty} (x-\mu)^2 \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\} dx \\ &= \frac{\sigma^2}{\sqrt{2\pi}} \int_{-\infty}^{\infty} t^2 \exp\left\{-\frac{t^2}{2}\right\} dt = \frac{\sigma^2}{\sqrt{2\pi}} \int_{-\infty}^{\infty} t \left(-\exp\left\{-\frac{t^2}{2}\right\}\right)' dt \\ &= t\left(-\exp\left\{-\frac{t^2}{2}\right\}\right)\Big|_{-\infty}^{\infty} - \frac{\sigma^2}{\sqrt{2\pi}} \int_{-\infty}^{\infty} \left(-\exp\left\{-\frac{t^2}{2}\right\}\right) dt \\ &= 0 - 0 + \sigma^2 \int_{-\infty}^{\infty} \varphi(t)dt = \sigma^2. \end{aligned}$$

3) Să se arate că: $X \sim N(\mu, \sigma^2) \iff \frac{X-\mu}{\sigma} \sim N(0,1)$.
R.: Funcţia de densitate pentru distribuţia $N(\mu, \sigma^2)$ este

$$f_{N(\mu,\sigma^2)}(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\}, x \in \mathbb{R}.$$

Funcţia de densitate pentru $N(0,1)$ este

$$f_{N(0,1)}(y) = \frac{1}{\sqrt{2\pi}} \exp\left\{-\frac{y^2}{2}\right\}, y \in \mathbb{R}.$$

Notăm cu $Y = \frac{X-\mu}{\sigma}$.
"$\Rightarrow$" Pentru orice $y \in \mathbb{R}$ are loc:

$$F_Y(y) = P(Y \le y) = P\left(\frac{X-\mu}{\sigma} \le y\right) = P(X \le \sigma y + \mu) = F_X(\sigma y + \mu).$$

Prin derivare în raport cu y se obţine

$$f_Y(y) = F_Y'(y) = F_X'(\sigma y + \mu) \cdot \sigma = f_X(\sigma y + \mu) \cdot \sigma = \frac{1}{\sqrt{2\pi}} \exp\left\{-\frac{y^2}{2}\right\},$$

care este funcţia de densitate pentru $N(0,1)$. Deci $Y \sim N(0,1)$.
"$\Leftarrow$" Pentru orice $x \in \mathbb{R}$ are loc:

$$F_X(x) = P(X \leq x) = P\left(\frac{X-\mu}{\sigma} \leq \frac{x-\mu}{\sigma}\right) = P\left(Y \leq \frac{x-\mu}{\sigma}\right) = F_Y\left(\frac{x-\mu}{\sigma}\right).$$

Prin derivare în raport cu x se obţine

$$f_X(x) = F_X'(x) = F_Y'\left(\frac{x-\mu}{\sigma}\right) \cdot \frac{1}{\sigma} = f_Y\left(\frac{x-\mu}{\sigma}\right) \cdot \frac{1}{\sigma} = \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\},$$

care este funcţia de densitate pentru $N(\mu, \sigma^2)$. Deci $X \sim N(\mu, \sigma^2)$. ♣